

# 第一章 参数估计



您的课程《数理统计》已经上线到学堂在线平台啦[Party]以下是课程选课地址和课程宣传小图  
<https://www.xuetangx.com/course/buaaP0701oli>

## 数理统计

北京航空航天大学



韦卫



孙海燕

等



长按识别二维码

4 January 2025



# 第一章 参数估计

- § 1.0 统计量简介
- § 1.1 频率估计
- § 1.2 矩估计
- § 1.3 极大似然估计
- § 1.4 估计优良性
- § 1.5 一致最小方差无偏估计
- § 1.6 信息不等式
- § 1.7 相合估计





## § 1.0 统计量简介

统计的核心任务是把样本中所包含的总体的信息提取出来，面对分布族 $\{P_\theta, \theta \in \Theta\}$ ，其本质就是对参数 $\theta$ 的推断和分析。

定义：设 $X_1, X_2, \dots, X_n$ 为来自总体 $X$ 简单样本，若样本的函数 $T(X_1, X_2, \dots, X_n)$ 中不包含任何未知参数，则称此函数为统计量。





例如：设 $X_1, X_2, \dots, X_n$ 是来自正态总体 $N(\mu, \sigma_0^2)$ 简单样本，其中 $\mu$ 是未知参数， $\sigma_0^2$ 已知，则 $\bar{X} = \frac{1}{n} \sum_{i=1}^n X_i$ ，

$S^2 = \frac{1}{n-1} \sum_{i=1}^n (X_i - \bar{X})^2$ ， $\frac{(n-1)S^2}{\sigma_0^2}$ 都是统计量，而

$\frac{1}{n-1} \sum_{i=1}^n (X_i - \mu)^2$ 不是统计量，因为它含有未知参数 $\mu$





常用统计量:

样本均值 (Sample Mean) :

$$\bar{X} = \frac{1}{n} \sum_{i=1}^n X_i.$$

样本方差 (Sample Variance) :

$$s^2 = \frac{1}{n-1} \sum_{i=1}^n (X_i - \bar{X})^2.$$



**样本标准差 (Sample Standard Deviation) :**

$$s = \sqrt{\frac{1}{n-1} \sum_{i=1}^n (X_i - \bar{X})^2}.$$

**样本矩 (Sample Moment)**

**$k$ 阶原点矩**

$$A_k = \frac{1}{n} \sum_{i=1}^n X_i^k, k = 1, 2, \dots.$$

**$k$ 阶中心矩**

$$B_k = \frac{1}{n} \sum_{i=1}^n (X_i - \bar{X})^k, k = 1, 2, \dots.$$



由大数定律可知，上述各种样本原点矩、样本中心矩、样本方差等都依概率收敛到对应的总体原点矩、总体中心矩、总体方差。





## 顺序统计量

$X_1, X_2, \dots, X_n$  观察值  $x_1, x_2, \dots, x_n$  按从小到大递增顺序排序, 记为  $x_{(1)}, x_{(2)}, \dots, x_{(n)}$ , 它满足  $x_{(1)} \leq x_{(2)} \leq \dots \leq x_{(n)}$ 。定义排在  $k$  位置的数  $x_{(k)}$  ( $1 \leq k \leq n$ ) 为随机变量  $X_{(k)}$  的观察值, 显然  $X_{(1)} \leq X_{(2)} \leq \dots \leq X_{(n)}$ 。由于  $X_{(k)}$  是样本  $X_1, X_2, \dots, X_n$  的函数, 且不含任何未知参数, 因而  $X_{(k)}$  是统计量, 称  $X_{(1)}, X_{(2)}, \dots, X_{(n)}$  为顺序统计量。







特别地,  $X_{(1)} = \min \{X_1, X_2 \dots X_n\}$  表示样本  $X_1, X_2, \dots, X_n$  最小的, 其观察值是样本观察值中最小。而  $X_{(n)} = \max \{X_1, X_2 \dots X_n\}$  表示样本  $X_1, X_2, \dots, X_n$  最大, 观察值是样本观察值中最大。如果总体  $X$  的分布函数为  $F(x)$ , 则容易求得  $X_{(1)}$  的分布函数为  $F_{X_{(1)}}(t) = 1 - [1 - F(t)]^n$ ,  $X_{(n)}$  的分布函数为  $F_{X_{(n)}}(t) = F^n(t)$ 。





基于顺序统计量，可以构造一些常用的统计量，如样本极差，样本分位数等。

样本极差定义为 $R = X_{(n)} - X_{(1)}$ ，它是一个描述数据分散程度的常用统计量。与样本方差 $S^2$ 和样本二阶中心矩 $\hat{\sigma}^2$ 相比，它仅仅使用了样本的最小值和最大值，计算简便，这也决定了它只能用来粗略描述数据分散程度，没有 $S^2$ 和 $\hat{\sigma}^2$ 精细准确。






样本中位数的定义如下：

$$m_{0.5} = \begin{cases} X_{(\frac{n+1}{2})}, & n \text{ 是奇数} \\ \frac{1}{2} \left( X_{(\frac{n}{2})} + X_{(\frac{n}{2}+1)} \right) & n \text{ 是偶数} \end{cases}$$

它表示把样本观察值从小到大进行排序时处在中间的数，反映了样本的平均值。



更一般的是样本的 $p$  ( $0 < p < 1$ )分位数 $m_p$ , 其定义为

$$m_p = \begin{cases} X_{([np+1])}, & np \text{不是整数} \\ \frac{1}{2} (X_{(np)} + X_{(np+1)}) & np \text{是整数} \end{cases}$$

由 $X_{(1)}$ 、 $X_{(n)}$ 、 $m_{0.25}$ 、 $m_{0.5}$ 、 $m_{0.75}$ 五个数字组成五数概括, 反映数据的大致分布

例：设 $X_1, X_2 \dots X_n$ 是来自总体 $X$ 的简单样本，且总体方差 $Var(X)$ 存在，试证：

$$(1) E(\bar{X}) = E(X); (2) Var(\bar{X}) = \frac{1}{n} Var(X);$$

$$(3) E(S^2) = Var(X).$$

证明： (1)  $E(\bar{X}) = \frac{1}{n} \sum_{i=1}^n E(X_i) = E(X)$

$$\begin{aligned} (2) \quad Var(\bar{X}) &= Var\left(\frac{1}{n} \sum_{i=1}^n X_i\right) \\ &= \frac{1}{n^2} \sum_{i=1}^n Var(X_i) = \frac{1}{n} Var(X) \end{aligned}$$


$$\begin{aligned} (3) \quad E(S^2) &= E\left[\frac{1}{n-1} \sum_{i=1}^n (X_i - \bar{X})^2\right] \\ &= E\left[\frac{1}{n-1} \left(\sum_{i=1}^n X_i^2 - n\bar{X}^2\right)\right] \\ &= \frac{1}{n-1} \left[\sum_{i=1}^n E(X_i^2) - nE(\bar{X}^2)\right] \end{aligned}$$



$$\begin{aligned} &= \frac{1}{n-1} [nE(X^2) - nE(\bar{X}^2)] \\ &= \frac{n}{n-1} [E(X^2) - E(\bar{X}^2)] \\ &= \frac{n}{n-1} \{Var(X) + [E(X)]^2 - Var(\bar{X}) - [E(\bar{X})]^2\} \\ &= \frac{n}{n-1} [Var(X) - Var(\bar{X})] \\ &= \frac{n}{n-1} \left[ Var(X) - \frac{1}{n} Var(X) \right] \\ &= Var(X) \end{aligned}$$



统计量既然是对样本的加工或压缩，在这个过程中可能有损失有关参数的一部分信息，现在问题是在这个过程中是否存在某些统计量，既起到压缩作用，又不损失参数的信息，这样的统计量称为充分统计量。





例：设样本的观察值为 $x_1, x_2, \dots, x_n$ , 则样本的联合分布函数为

$$P(X_1 = x_1, X_2 = x_2, \dots, X_n = x_n) = \theta^s (1 - \theta)^{n-s}, \text{其中 } x_i = 0 \text{ 或 } 1, s = \sum_{i=1}^n x_i$$

给定 $s$ 的条件下, 样本的条件分布为

$$P(X_1 = x_1, X_2 = x_2, \dots, X_n = x_n | s) = \frac{1}{\binom{n}{s}}$$

定义： 设总体分布族为 $\{P_\theta, \theta \in \Theta\}$ ,  $T(X)$ 是统计量。  
如果在给定 $T(X) = t$ 的条件下,  $X$ 的条件分布与参数 $\theta$ 无关, 则称统计量 $T(X)$ 是参数 $\theta$ 的充分统计量  
(Sufficient Statistics)

一般情况下, 利用条件分布证明统计量的充分性是比较困难的。但存在证明充分性的一个充分必要准则, 这是下面的因式分解定理(Factorization theorem)。



定理： 设总体分布族为 $\{P_\theta, \theta \in \Theta\}$ ,  $T(X)$ 是充分的，当且仅当存在一个定义在 $I \times \Theta$ 上的函数 $g(t, \theta)$ 及定义在 $R^n$ 上的函数 $h(x)$ 使得

$$p(x, \theta) = g(T(x), \theta)h(x)$$

对所有的 $x \in R^n$ 都成立，其中 $I$ 是 $T(x)$ 的值域， $p(x, \theta)$ 是样本的联合概率密度函数或分布率。



例： 设 $x_1, x_2, \dots, x_n$ 来自Poisson分布总体 $P(x; \lambda)$ 简单样本，求参数 $\lambda$ 的充分统计量。

解 样本 $x_1, x_2, \dots, x_n$ 的联合分布列为

$$p(x_1, x_2, \dots, x_n; \lambda) = \frac{e^{-n\lambda}}{x_1! x_2! \dots x_n!} \lambda^{\sum_{i=1}^n x_i}$$

取 $T(x) = \sum_{i=1}^n x_i$ ,  $g(t, \lambda) = e^{-n\lambda} \lambda^t$ ,  $h(x) = \frac{1}{x_1! x_2! \dots x_n!}$ ,

则有

$$p(x; \lambda) = g(T(x), \lambda) h(x)$$

可知， $T(x) = \sum_{i=1}^n x_i$ 为参数 $\lambda$ 的充分统计量

例：设 $x_1, x_2, \dots, x_n$ 是来自正态总体 $N(\mu, \sigma^2)$ 的简单样本，其中 $\mu$ 和 $\sigma^2$ 都是未知的，令参数 $\theta = (\mu, \sigma^2)$ ，试证明

$T(x) = (\sum_{i=1}^n x_i, \sum_{i=1}^n x_i^2)$ 及

$S(x) = (\sum_{i=1}^n x_i, \sum_{i=1}^n (x_i - \bar{x})^2)$ 都是 $\theta$ 的充分统计量。

证明： 样本联合密度函数为 $p(x_1, x_2, \dots, x_n; \theta)$

$$\begin{aligned} &= \left( \frac{1}{\sqrt{2\pi\sigma^2}} \right)^n \exp \left\{ -\frac{1}{2\sigma^2} \sum_{i=1}^n (x_i - \mu)^2 \right\} \\ &= \left( \frac{1}{\sqrt{2\pi\sigma^2}} \right)^n \exp \left\{ -\frac{1}{2\sigma^2} \left( \sum_{i=1}^n x_i^2 - 2\mu \sum_{i=1}^n x_i + n\mu^2 \right) \right\} \end{aligned}$$

若取  $T(x) = (T_1(x), T_2(x)) = (\sum_{i=1}^n x_i, \sum_{i=1}^n x_i^2)$ ,

$h(x) \equiv 1$  及

$$g(t, \theta) = \left( \frac{1}{\sqrt{2\pi\sigma^2}} \right)^n \exp \left\{ -\frac{1}{2\sigma^2} (t_2 - 2\mu t_1 + n\mu^2) \right\}$$

其中  $t = (t_1, t_2)$ , 则有

$$p(x_1, x_2, \dots, x_n; \theta) = g(t, \theta)h(x)$$

由因式分解定理可知,

$T(x) = (\sum_{i=1}^n x_i, \sum_{i=1}^n x_i^2)$  是  $\theta$  的充分统计量。

又因为样本的联合密度函数可表示为

$$p(x_1, x_2, \dots, x_n; \theta) \\ = \left( \frac{1}{\sqrt{2\pi\sigma^2}} \right)^n \exp \left\{ -\frac{1}{2\sigma^2} \left[ \sum_{i=1}^n (x_i - \bar{x})^2 + n(\bar{x} - \mu)^2 \right] \right\}$$

若取  $S(x) = (S_1(x), S_2(x)) = (\sum_{i=1}^n x_i, \sum_{i=1}^n (x_i - \bar{x})^2)$ ,

$h(x) \equiv 1$  及

$$g(s, \theta) = \left( \frac{1}{\sqrt{2\pi\sigma^2}} \right)^n \exp \left\{ -\frac{1}{2\sigma^2} \left[ s_2 + n \left( \frac{s_1}{n} - \mu \right)^2 \right] \right\}$$

其中  $s = (s_1, s_2)$ , 则有

$$p(x_1, x_2, \dots, x_n; \theta) = g(s, \theta)h(x)$$

由因式分解定理可知,  $S(x) = (\sum_{i=1}^n x_i, \sum_{i=1}^n (x_i - \bar{x})^2)$  也是  $\theta$  的充分统计量。





例：设  $x_1, x_2, \dots, x_n$  是来自均匀分布总体  $U[a, b]$  的简单样本，其中  $a$  和  $b$  都是未知的，且  $a < b$ ，令参数  $\theta = (a, b)$ ，求  $\theta$  的充分统计量。

解： 样本的联合密度函数为

$$\begin{aligned} p(x_1, x_2, \dots, x_n; \theta) &= \prod_{i=1}^n p(x_i; \theta) \\ &= \frac{1}{(b-a)^n} I_{\{a \leq x_{(1)} \leq x_{(n)} \leq b\}}(x_1, x_2, \dots, x_n) \\ &= \frac{1}{(b-a)^n} I_{\{a \leq x_{(1)} \leq x_{(n)} \leq b\}}(x_{(1)}, x_{(n)}) \end{aligned}$$



其中

$$I_A(u) = \begin{cases} 1, & u \in A \\ 0, & u \notin A \end{cases}$$

称其为示性函数。

$$\text{令 } T(x) = (x_{(1)}, x_{(n)}),$$

$$g(t, \theta) = \frac{1}{(b-a)^n} I_{\langle a \leq t_1 \leq t_2 \leq b \rangle}(t_1, t_2), \quad h(x) \equiv 1$$

其中  $t = (t_1, t_2)$ , 则联合密度函数有分解式

$$p(x_1, x_2, \dots, x_n; \theta) = g(t, \theta)h(x)$$

由因式分解定理可知,  $T(x) = (x_{(1)}, x_{(n)})$  是  $\theta$  的充分统计量。

本例说明，一方面，参数分布族 $\{P_{\theta}: \theta \in \Theta\}$ 中参数 $\theta$ 的充分统计量 $T$ 不唯一。一般情况下，若 $T(x)$ 是充分统计量， $g(t)$ 是一一对应的实函数（可以是向量函数），则 $g(T(x))$ 也是充分统计量。

另一方面，当参数维数和充分统计量维数相等的时候，应将充分统计量看成一个有机整体，不能拆分，认为充分统计量的分量是相应参数向量的充分统计量是错误的。

值得指出，对一个分布族 $\{P_{\theta}: \theta \in \Theta\}$ 而言，充分统计量往往不唯一，都具有保留分布信息的特点，但在对样本进行加工处理剔除与参数无关的信息能力，或者说压缩数据能力方面各不相同。

例如，总体分布族是两点分布族 $\{B(1, \theta): 0 < \theta < 1\}$ ，统计量 $(x_1, x_2, \dots, x_n)$ 、 $(\sum_{i=1}^{n-1} x_i, x_n)$ 、 $\sum_{i=1}^n x_i$ 都是充分统计量。

上述统计量都保留了与参数 $\theta$ 有关的信息“1”的个数，但在剔除无关信息“1”的位置方面，

$(x_1, x_2, \dots, x_n)$ 最差， $(\sum_{i=1}^{n-1} x_i, x_n)$ 次之，而 $\sum_{i=1}^n x_i$ 做的最好，它除了保留所有与 $\theta$ 有关的信息外，还剔除了所有与 $\theta$ 无关的信息，或者从压缩数据能力方面看， $\sum_{i=1}^n x_i$ 最强，再没有比 $\sum_{i=1}^n x_i$ 更强的充分统计量了。这种统计量称为**最小充分统计量**。

## § 1.1 频率估计

**参数估计：** 所谓参数估计，就是对来自总体的样本  $x_1, x_2, \dots, x_n$  构造合适的统计量  $T(x_1, x_2, \dots, x_n)$  作为参数  $q(\theta)$  的估计，记为  $\hat{q}(x_1, x_2, \dots, x_n) = T(x_1, x_2, \dots, x_n)$ ，也简称为  $\hat{q}(x) = T(x)$ ，其中  $x = (x_1, x_2, \dots, x_n)$ 。

考虑 $n$ 次独立重复实验，每次实验有 $m$ 种可能的结果 $D_1, D_2, \dots, D_m$ ，每个结果 $D_i$ 发生的概率 $P(D_i) = p_i$ 是未知的，且 $\sum_{i=1}^m p_i = 1$ 。用 $n_i$ 表示 $n$ 次独立重复试验结果 $D_i$ 发生的次数，则 $(n_1, n_2, \dots, n_m)$ 的精确分布称为多项分布，其分布列为

$$p(n_1, n_2, \dots, n_m) = \frac{n!}{n_1! n_2! \dots n_m!} p_1^{n_1} p_2^{n_2} \dots p_m^{n_m}$$



其中 $\sum_{i=1}^m n_i = n$ 。多项分布是二项分布推广。概率

$p_i$ 最直观估计是 $\frac{n_i}{n}$ ，即 $\hat{p}_i = \frac{n_i}{n}$ ，称 $\hat{p}_i$ 为 $p_i (i = 1, 2, \dots, m)$ 的频率替换估计(*Frequency Substitution Estimate*)。

一般的，考虑 $p_i$ 的连续函数 $q(p_1, p_2, \dots, p_m)$ 的估计问题。由频率替换原理，最自然的方法就是用样本频率

$\frac{n_1}{n}, \frac{n_2}{n}, \dots, \frac{n_m}{n}$ 来替换未知概率 $p_1, p_2, \dots, p_m$ ，使用

$q\left(\frac{n_1}{n}, \frac{n_2}{n}, \dots, \frac{n_m}{n}\right)$ 来估计 $q(p_1, p_2, \dots, p_m)$ 。





**例1.1.1:** 设总体 $X$ 服从正态分布 $N(\mu, \sigma_0^2)$ , 其中 $\sigma_0^2$ 已知,  $x_1, x_2, \dots, x_n$ 是简单样本。由于某种原因, 原始数据 $x_1, x_2, \dots, x_n$ 已不存在, 仅知道 $n$ 个观察值中有 $m$ 个数不小于1, 求 $\mu$ 的频率替换估计。

解 由已知条件, 需求概率 $p = P\{X \geq 1\}$ 。因为

$$p = P\{X \geq 1\} = P\left\{\frac{X - \mu}{\sigma_0} \geq \frac{1 - \mu}{\sigma_0}\right\} = 1 - \Phi\left(\frac{1 - \mu}{\sigma_0}\right)$$

其中 $\Phi(x)$ 是标准正态分布的分布函数, 所以

$$\mu = 1 - \sigma_0 \Phi^{-1}(1 - p)$$

用频率 $\frac{m}{n}$ 替换相应概率 $p$ , 可得 $\mu$ 的频率替换估计为

$$\mu = 1 - \sigma_0 \Phi^{-1}\left(1 - \frac{m}{n}\right)$$

**例1.1.2(Hardy-Weinberg模型):** 考虑具有两个等位基因的单个基因的遗传平衡问题。如果三种不同的基因型是可辨识的, 分别用 $l_1, l_2, l_3$ 表示, 并假设个体三种基因型发生的概率分别为

$$p_1 = \theta^2, p_2 = 2\theta(1 - \theta), p_3 = (1 - \theta)^2$$

其中 $\theta(0 < \theta < 1)$ 表示等位基因之一发生的概率。独立观测 $n$ 个个体, 三种基因型出现的次数分别为 $n_1, n_2, n_3$ , 试求参数 $\theta$ 的频率替换估计。

解：  $n$ 个个体中，三种基因型发生的频率分别为

$$\hat{p}_1 = \frac{n_1}{n}, \hat{p}_2 = \frac{n_2}{n}, \hat{p}_3 = \frac{n_3}{n}$$

而 $\theta$ 有三种表达式，分别为

$$\theta = \sqrt{p_1}, \theta = 1 - \sqrt{p_3}, \theta = p_1 + \frac{p_2}{2}$$

由频率替换原理可得参数 $\theta$ 的三个不同的估计分别为

$$\hat{\theta}_1 = \sqrt{\frac{n_1}{n}}, \hat{\theta}_2 = 1 - \sqrt{\frac{n_3}{n}}, \hat{\theta}_3 = \frac{n_1}{n} + \frac{n_2}{2n}$$

## § 1.2 矩估计

矩估计法的主要思想是基于替换原理。设总体分布族为  $\{P_\theta: \theta \in \Theta\}$ ,  $\theta = (\theta_1, \theta_2, \dots, \theta_s)$ , 其  $r$  ( $r \geq s$ ) 阶原点矩  $E_\theta(X^r)$  存在, 令

$$\mu_k = E_\theta(X^k) = g_k(\theta_1, \theta_2, \dots, \theta_s), \quad k = 1, 2, \dots, r$$

选择其中  $s$  ( $s \leq r$ ) 个方程, 不妨设是前  $s$  ( $s \leq r$ ) 个, 若通过反解, 可将  $\theta_j$  表示成  $\mu_i$  函数, 即

$$\begin{cases} \theta_1 = h_1(\mu_1, \mu_2, \cdots, \mu_s) \\ \theta_2 = h_2(\mu_1, \mu_2, \cdots, \mu_s) \\ \cdots \cdots \cdots \\ \theta_s = h_s(\mu_1, \mu_2, \cdots, \mu_s) \end{cases}$$

相应的样本前 $r$ 个原点矩为

$$A_k = \frac{1}{n} \sum_{i=1}^n X_i^k, \quad k = 1, 2, \cdots, r$$

用样本矩 $A_k$ 替换相应总体矩 $\mu_k$ ，可得参数 $\theta$ 的估计为



$$\left\{ \begin{array}{l} \hat{\theta}_1 = h_1(A_1, A_2, \dots, A_s) = h_1 \left( \frac{1}{n} \sum_{i=1}^n x_i, \frac{1}{n} \sum_{i=1}^n x_i^2, \dots, \frac{1}{n} \sum_{i=1}^n x_i^s \right) \\ \hat{\theta}_2 = h_2(A_1, A_2, \dots, A_s) = h_2 \left( \frac{1}{n} \sum_{i=1}^n x_i, \frac{1}{n} \sum_{i=1}^n x_i^2, \dots, \frac{1}{n} \sum_{i=1}^n x_i^s \right) \\ \dots\dots\dots \\ \hat{\theta}_s = h_s(A_1, A_2, \dots, A_s) = h_s \left( \frac{1}{n} \sum_{i=1}^n x_i, \frac{1}{n} \sum_{i=1}^n x_i^2, \dots, \frac{1}{n} \sum_{i=1}^n x_i^s \right) \end{array} \right.$$

这种方法称为矩估计法，所得的估计量称为矩估计量 (*Moment Estimate*)。



**例1.2.1:** 设总体 $X$ 的二阶矩 $\mu_2 = E(X^2)$ 存在,  $x_1, x_2, \dots, x_n$ 是简单样本, 试求总体均值 $\mu = E(X)$ 和方差 $\sigma^2 = \text{Var}(X)$ 的矩估计。

解 因为  $\mu_1 = E(X) = \mu$ ,  $\mu_2 = E(X^2) = \text{Var}(X) + [E(X)]^2 = \sigma^2 + \mu^2$ , 解方程组

$$\begin{cases} \mu_1 = \mu \\ \mu_2 = \sigma^2 + \mu^2 \end{cases}$$

可得,  $\mu = \mu_1$ ,  $\sigma^2 = \mu_2 - \mu_1^2$ 。

用 $A_1$ 和 $A_2$ 分别替换 $\mu_1$ 和 $\mu_2$ , 可得总体均值 $\mu$ 和方差 $\sigma^2$ 的矩估计分别为 $\hat{\mu} = \bar{x}$ 及 $\hat{\sigma}^2 = \frac{1}{n} \sum_{i=1}^n x_i^2 - \bar{x}^2 = \frac{1}{n} \sum_{i=1}^n (x_i - \bar{x})^2$ 。



**例1.2.2:** 设总体 $X$ 在 $[a, b]$ 上服从均匀分布, 其概率密度函数为

$$p(x; a, b) = \begin{cases} \frac{1}{b-a}, & x \in [a, b] \\ 0, & x \notin [a, b] \end{cases}$$

其中 $b > a$ ,  $x_1, x_2, \dots, x_n$ 是简单样本, 试求 $a$ 和 $b$ 的矩估计。

解 由于 $\mu_1 = E(X) = \frac{1}{2}(a+b)$ ,  $v_2 = \text{Var}(X) = \frac{1}{12}(b-a)^2$ , 解方程组

$$\begin{cases} \mu_1 = \frac{1}{2}(a+b) \\ v_2 = \frac{1}{12}(b-a)^2 \end{cases}$$

可得 $a = \mu_1 - \sqrt{3v_2}$ 和 $b = \mu_1 + \sqrt{3v_2}$ 。



因此，用样本均值 $\bar{x}$ 替换总体均值 $\mu_1$ ，样本二阶中心矩 $B_2$ 替换总体二阶中心矩 $v_2$ ，可得参数 $a$ 和 $b$ 的矩估计分别为 $\hat{a} = \bar{x} - \sqrt{3}\hat{\sigma}$ ,  $\hat{b} = \bar{x} + \sqrt{3}\hat{\sigma}$ ，其中

$$\sigma^2 = \frac{1}{n} \sum_{i=1}^n (x_i - \bar{x})^2。$$



注意：

1. 总体存在适当阶的矩。

反例，考虑Cauchy分布，其密度函数为

$$f(x, \theta) = \frac{1}{\pi(1 + (x - \theta)^2)}, -\infty < x < +\infty$$

其各阶矩均不存在。

2. 对相同的参数 $q(\theta)$ ，存在多个矩估计。

例如，考虑总体是参数为 $\lambda$ 的Poisson分布，即使 $\lambda$ 总体的均值，又是总体的方差。



## § 1.3 极大似然估计

极大似然法是另一种常用的估计法，先举例说明其思想。

**例1.3.1** 已知甲、乙两射手命中靶心的概率为0.9和0.4，观察一张靶纸知10枪六中，且这张靶纸肯定是射手甲乙其中一人所射，问究竟是谁所射？



根据题意，可建立统计模型 $\{P_\theta, \theta \in \Theta\}$ ，其中 $\Theta = \{0.9, 0.4\}$ ，当 $\theta$ 取定时， $P_\theta$ 具有两点分布形式。设 $x_1, x_2, \dots, x_{10}$ 是样本值，则射中的概率为

$$L(\theta) = \theta^{\sum_{i=1}^{10} x_i} (1 - \theta)^{10 - \sum_{i=1}^{10} x_i}, \theta \in \Theta$$

通过计算可知  $L(0.9) \approx 0.00005$ ,  $L(0.4) \approx 0.0005$ ，比较这两个值，可知射中的概率 $L(\theta)$ 在 $\theta = 0.4$ 时最大，因此更愿接受这张靶纸是乙所射的，即用0.4作为 $\theta$ 的估计， $\hat{\theta} = 0.4$ 。



从这个例子可以看出，极大似然法是基于这样一个统计原理：在一次试验中，某一事件已经发生，则必认为发生该事件的概率最大（小概率事件原理）。

设  $x_1, x_2, \dots, x_n$  来自总体的样本，总体的分布族为  $p(x, \theta), \theta \in \Theta$ ，则  $x_1, x_2, \dots, x_n$  的联合分布为

$$L(\theta; x_1, x_2, \dots, x_n) = \prod_{i=1}^n p(x_i, \theta)$$



其中 $L(\theta; x_1, x_2, \dots, x_n)$ 称之为似然函数 (*Likelihood Function*)，简记为 $L(\theta)$ ，它是定义在参数空间 $\Theta$ 上函数

如果存在 $\hat{\theta} \in \Theta$ ，使 $L(\theta)$ 达到最大，即

$$L(\hat{\theta}(x); x) = \sup_{\theta \in \Theta} \{L(\theta, x)\} = \sup_{\theta \in \Theta} \left\{ \prod_{i=1}^n p(x_i, \theta) \right\}$$

则称为参数 $\hat{\theta}(x)$ 的极大似然估计 (*Maximum Likelihood Estimate*)，简称为MLE。相应的，称 $q(\hat{\theta}(x))$ 为 $q(\theta)$ 的MLE。





注意：

当总体 $X$ 为离散随机变量时， $p(x, \theta)$ 为分布率（分布列）；而当总体为连续随机变量时， $p(x, \theta)$ 为概率密度函数。

从以上分析可知，求 $\theta$ 的MLE $\hat{\theta}(x)$ ，等价于求 $L(\theta, x)$ 在 $\theta \in \Theta$ 上的最大值。





求极大似然估计的具体过程可归如下：

1. 当参数空间仅含有限个元时，可以用穷举法求使 $L(\theta, x)$ 在 $\Theta$ 上取得最大的 $\hat{\theta}(x)$ 。
2. 当参数空间 $\Theta$ 包含 $m$ 维欧氏空间的一个域时，可以先对 $L(\theta, x)$ 取对数，得对数似然函数 $\ln L(\theta, x)$ ，令偏导数等于零，即

$$\frac{\partial \ln L(\theta, x)}{\partial \theta_i} = 0, i = 1, 2, \dots, n$$

这个方程称为似然方程（Likelihood Function），求解似然方程可获得参数的MLE $\hat{\theta}(x)$ 。





**例1.3.2:** 考虑 $n$ 次独立重复试验, 每次试验有 $m$ 种可能结果 $v_1, v_2, \dots, v_m$ , 每个结果发生概率 $p_i$ 是未知的, 且 $\sum_{i=1}^m p_i = 1$ 。  $x_1, x_2, \dots, x_n$ 是进行 $n$ 次试验得到的简单样本。求 $p_i$ 的极大似然估计。

解 若用 $n_i (i = 1, 2, \dots, m)$ 表示样本 $x_1, x_2, \dots, x_n$ 中取值 $v_i$ 的次数, 则 $\sum_{i=1}^m n_i = n$ 。此时, 似然函数为

$$L(p_1, p_2, \dots, p_m) = p_1^{n_1} p_2^{n_2} \cdots p_m^{n_m}$$



注意限制 $\sum_{i=1}^m n_i = n$ 和 $\sum_{i=1}^m p_i = 1$ 。对数似然函数为

$$\ln L(p_1, p_2, \dots, p_m) = \sum_{i=1}^{m-1} n_i \ln p_i + n_m \ln \left( 1 - \sum_{i=1}^{m-1} p_i \right)$$

求偏导，可得似然方程组

$$\frac{\partial}{\partial p_i} \ln L(p_1, p_2, \dots, p_m) = \frac{n_i}{p_i} - \frac{n_m}{1 - \sum_{i=1}^{m-1} p_i} = \frac{n_i}{p_i} - \frac{n_m}{p_m} = 0$$

$$i = 1, 2, \dots, m-1$$

求解可得参数的极大似然估计为 $\hat{p}_i = \frac{n_i}{n}, i = 1, 2, \dots, m$

**例1.3.3:** 考虑Hardy-Weinberg模型,  $x_1, x_2, \dots, x_n$  是简单样本, 记三种不同基因型发生的次数分别为  $n_1, n_2, n_3$ ,  $n = n_1 + n_2 + n_3$ , 试求等位基因之一发生的概率  $\theta$  的极大似然估计。

解 似然函数为

$$L(\theta) = p_1^{n_1} p_2^{n_2} p_3^{n_3} = 2^{n_2} \theta^{2n_1+n_2} (1-\theta)^{n_2+2n_3}$$

对数似然函数为

$$\ln L(\theta) = n_2 \ln 2 + (2n_1 + n_2) \ln \theta + (n_2 + 2n_3) \ln(1 - \theta)$$

求偏导，有

$$\frac{\partial \ln L(\theta)}{\partial \theta} = \frac{2n_1 + n_2}{\theta} - \frac{n_2 + 2n_3}{1 - \theta}$$

令  $\frac{\partial \ln L(\theta)}{\partial \theta} = 0$ ，可得的极大似然估计为

$$\hat{\theta} = \frac{n_1}{n} + \frac{n_2}{2n}$$

**例1.3.4:** 设总体 $X$ 为正态分布族 $\{N(\mu, \sigma^2): (\mu, \sigma^2) \in \Theta\}$ ,  $x_1, x_2, \dots, x_n$ 是简单样本, 在参数空间 $\Theta = \{(\mu, \sigma^2): \mu \in \mathbf{R}, \sigma^2 > 0\}$ 和 $\Theta_0 = \{(\mu, \sigma^2): \mu \geq 0, \sigma^2 > 0\}$ , 分别求参数 $\mu$ 和 $\sigma^2$ 的极大似然估计。

**解** 首先考虑参数空间 $\Theta = \{(\mu, \sigma^2): \mu \in \mathbf{R}, \sigma^2 > 0\}$ 。

由于总体的密度函数为

$$p(x; \mu, \sigma^2) = \frac{1}{\sqrt{2\pi\sigma}} e^{-\frac{(x-\mu)^2}{2\sigma^2}}$$

$\{N(\mu, \sigma^2): (\mu, \sigma^2) \in \Theta\}$ ,  $x_1, x_2, \dots, x_n$  是简单样本, 在所以, 对数似然函数为

$$\ln L(\mu, \sigma^2) = -\frac{n}{2} \ln(2\pi) - \frac{n}{2} \ln \sigma^2 - \frac{1}{2\sigma^2} \sum_{i=1}^n (x_i - \mu)^2$$

分别对  $\mu$  及  $\sigma^2$  求偏导数, 可得似然方程组

$$\left. \begin{aligned} \frac{1}{\sigma^2} \sum_{i=1}^n (x_i - \mu) &= 0 \\ -\frac{n}{2\sigma^2} + \frac{1}{2(\sigma^2)^2} \sum_{i=1}^n (x_i - \mu)^2 &= 0 \end{aligned} \right\}$$

解方程组可得

$$\hat{\mu} = \frac{1}{n} \sum_{i=1}^n x_i = \bar{x}, \quad \hat{\sigma}^2 = \frac{1}{n} \sum_{i=1}^n (x_i - \bar{x})^2$$

由于 $\ln L(\mu, \sigma^2)$ 在参数空间 $\Theta$ 上偏导数存在, 且有唯一的驻点 $(\hat{\mu}, \hat{\sigma}^2) \in \Theta$ , 因此 $\hat{\mu}$ 和 $\hat{\sigma}^2$ 分别是 $\mu$ 和 $\sigma^2$ 的极大似然估计。

其次, 考虑参数空间 $\Theta_0 = \{(\mu, \sigma^2): \mu \geq 0, \sigma^2 > 0\}$ 。若方程组的解中的第一个分量 $\bar{x} \geq 0$ , 则驻点 $(\bar{x}, \hat{\sigma}^2) \in \Theta_0$ , 且 $\ln L(\bar{x}, \hat{\sigma}^2) = \sup_{\theta \in \Theta_0} \{\ln L(\theta)\}$ , 所以 $\hat{\mu}_0 = \bar{x}$ 和 $\hat{\sigma}_0^2 = \hat{\sigma}^2$ 分别是参数 $\mu$ 和 $\sigma^2$ 的极大似然估计; 若 $\bar{x} < 0$ , 则 $(\bar{x}, \hat{\sigma}^2) \notin \Theta_0$ , 因而 $\bar{x}$ 和 $\hat{\sigma}^2$ 就不再是参数 $\mu$ 和 $\sigma^2$ 的极大似然估计。由于 $\bar{x} < 0$ , 且对任意的 $(\mu, \sigma^2) \in \Theta_0$ , 有

$$\frac{\partial \ln L(\mu, \sigma^2)}{\partial \mu} = \frac{n}{\sigma^2} (\bar{x} - \mu) < 0$$



所以,  $\ln L(\mu, \sigma^2)$  是  $\mu (\mu \geq 0)$  的单调减函数, 因而对数似然函数  $\ln L(\mu, \sigma^2)$  在参数空间  $\Theta_0$  的点  $(0, \frac{1}{n} \sum_{i=1}^n x_i)$  处取得最大, 由此可得  $\hat{\mu}_0 = 0$  和  $\hat{\sigma}^2 = \frac{1}{n} \sum_{i=1}^n x_i^2$  分别是  $\mu$  和  $\sigma^2$  的极大似然估计。综上所述, 在参数空间  $\Theta_0$  上, 统计量  $\hat{\mu}_0 = \max(\bar{x}, 0)$  和  $\hat{\sigma}_0^2 = \frac{1}{n} \sum_{i=1}^n (x_i - \hat{\mu}_0)^2$  分别是参数  $\mu$  和  $\sigma^2$  的极大似然估计。





**例1.3.5:** 设 $x_1, x_2, \dots, x_n$ 是来自均匀分布总体 $U[a, b]$ 的简单样本, 试求参数 $a$ 和 $b$ 的极大似然估计。

解 似然函数为

$$L(a, b) = \begin{cases} \frac{1}{(b-a)^n}, & a \leq x_{(1)} \leq x_{(n)} \leq b \\ 0, & \text{其他} \end{cases}$$

参数空间 $\Theta = \{(a, b): a < b\}$ 。从上式可知,  $L(a, b)$ 只可能在范围 $a \leq x_{(1)} \leq x_{(n)} \leq b$ 内取得最大值, 但两个偏导数:



$$\frac{\partial \ln L(a, b)}{\partial a} = \frac{n}{b-a}, \quad \frac{\partial \ln L(a, b)}{\partial b} = -\frac{n}{b-a}$$

均不可能为零，导致似然方程组无法用求导法求参数 $a$ 和 $b$ 的极大似然估计，而直接使用定义。由于样本 $x_1, x_2, \dots, x_n$ 给定时，其最小 $x_{(1)}$ 和最大 $x_{(n)}$ 亦给定，而参数满足 $a \leq x_{(1)}$ 及 $b \geq x_{(n)}$ 。

因此当 $a = x_{(1)}$ ,  $b = x_{(n)}$ 时， $(b - a)^n$ 取最小值 $(x_{(n)} - x_{(1)})^n$ ，相应的， $L(a, b)$ 取得最大值 $\frac{1}{(x_{(n)} - x_{(1)})^n}$ 。所以， $a$ 和 $b$ 的极大似然估计分别为 $\hat{a} = x_{(1)}$ 和 $\hat{b} = x_{(n)}$ 。





**例1.3.6:** 总体 $X$ 的密度函数为

$$f(x) = \begin{cases} 2e^{-2(x-\theta)}, & x > \theta \\ 0, & x \leq \theta \end{cases}$$

其中 $\theta > 0$ 是未知参数。 $x_1, x_2, \dots, x_n$ 是来自总体的简单样本。求 $\theta$ 的极大似然估计。

解 似然函数为

$$L(\theta; x_1, x_2, \dots, x_n) = \begin{cases} 2^n e^{-\sum_{i=1}^n 2(x_i - \theta)}, & x_{(1)} > \theta \\ 0, & \text{其他} \end{cases}$$

样本 $x_1, x_2, \dots, x_n$ 给定时，由于 $L(\theta; x_1, x_2, \dots, x_n)$ 是单调增函数，所以在 $\hat{\theta} = x_{(1)}$ 处取得上确界。因此的 $\theta$ 极大似然估计为 $x_{(1)}$ 。

**例1.3.7:** 设 $x_1, x_2, \dots, x_n$ 是来自正态总体 $N(\mu, \sigma^2)$ 的简单样本, 其中 $\mu$ 和 $\sigma^2$ 都是未知参数, 对给定的正常数 $a$ , 存在 $c$ , 使得 $P\{X \leq c\} = aP\{x \geq c\}$ 成立, 求 $c$ 的极大似然估计。

解 由条件 $P\{X \leq c\} = aP\{x \geq c\}$ 可得

$$P\{X \leq c\} = \frac{a}{a+1}, \quad \text{即} \quad P\left\{\frac{X-\mu}{\sqrt{\sigma^2}} \leq \frac{c-\mu}{\sqrt{\sigma^2}}\right\} = \frac{a}{a+1}$$

由于  $X \sim N(\mu, \sigma^2)$ , 所以  $\frac{X-\mu}{\sqrt{\sigma^2}} \sim N(0, 1)$ 。因而  $\frac{c-\mu}{\sqrt{\sigma^2}}$  是标准正态分布的  $\frac{a}{a+1}$  分位数, 即  $\frac{c-\mu}{\sqrt{\sigma^2}} = z_{\frac{a}{a+1}}$ , 求得  $c = \mu + z_{\frac{a}{a+1}} \sqrt{\sigma^2}$ 。

又由例1.3.4可知,  $\mu$  和  $\sigma^2$  的极大似然估计分别为

$$\hat{\mu} = \bar{x}, \quad \hat{\sigma}^2 = \frac{1}{n} \sum_{i=1}^n (x_i - \bar{x})^2$$

因而在极大似然估计为  $\hat{c} = \bar{x} + z_{\frac{a}{a+1}} \sqrt{\frac{1}{n} \sum_{i=1}^n (x_i - \bar{x})^2}$



若参数 $\theta$ 有一个充分统计量 $T(x)$ ，且极大似然估计 $\hat{\theta}$ 存在，则由因子分解定理得似然函数 $L(\theta; x) = g(T(x), \theta)h(x)$ ，所以 $\hat{\theta}$ 是充分统计量 $T(x)$ 函数，这是极大似然估计的优点。而矩估计却不具有这样的性质，例如，均匀分布总体 $U[a, b]$ 中参数 $a$ 和 $b$ 的矩估计 $\hat{a}$ 和 $\hat{b}$ 并不是充分统计量 $T(x) = (x_{(1)}, x_{(n)})$ 的函数。

若 $\theta$ 频率估计、矩估计、极大似然估计分别为 $\hat{\theta}_1, \hat{\theta}_2, \hat{\theta}_3$ ，则 $f(\theta)$ 的频率估计、矩估计、极大似然估计分别为 $f(\hat{\theta}_1), f(\hat{\theta}_2), f(\hat{\theta}_3)$ 。



## § 1.4 估计优良性

假设用 $T(x)$ 作为参数 $q(\theta)$ 的估计量，评价估计优劣的一个自然准则可定义如下：

$$MSE_{\theta}(T) = R(\theta, T) = E(T(x) - q(\theta))^2$$

称上式为均方误差(*Mean Squared Error*), 简记为MSE。

如果  $R(\theta, T) < +\infty$ , 则MSE由 $T$ 的均值和方差确定,  
即

$$R(\theta, T) = \text{Var}_{\theta}(T(x)) + b^2(\theta, T)$$

其中  $b(\theta, T) = E_{\theta}(T(x) - q(\theta))$

称  $b(\theta, T)$  为用  $T(x)$  估计  $q(\theta)$  产生的偏差(bias)。



**例1.4.1:** 设 $x_1, x_2, \dots, x_n$ 是来自正态总体 $N(\mu, \sigma^2)$ 的简单样本,  $\mu$ 和 $\sigma^2$ 都是未知, 试求总体均值 $\mu$ 和方差 $\sigma^2$ 的极大似然估计 $\bar{x}$ 和 $\hat{\sigma}^2$ 的均方误差。

解 令 $\theta = (\mu, \sigma^2), \Theta = \{(\mu, \sigma^2): \mu \in R, \sigma^2 > 0\}$ 。由于

$$\bar{x} \sim N\left(\mu, \frac{\sigma^2}{n}\right), \frac{n\hat{\sigma}^2}{\sigma^2} \sim \chi^2(n-1)$$

所以

$$b(\mu, \bar{x}) = 0, \text{Var}_{\theta}(\bar{x}) = \frac{\sigma^2}{n}$$
$$b(\sigma^2, \hat{\sigma}^2) = -\frac{\sigma^2}{n}, \text{Var}_{\theta}\left(\frac{n\hat{\sigma}^2}{\sigma^2}\right) = 2(n-1)$$

从而

$$MSE_{\theta}(\bar{x}) = \text{Var}(\bar{x}) + b^2(\mu, \bar{x}) = \frac{\sigma^2}{n}$$
$$MSE_{\theta}(\hat{\sigma}^2) = \text{Var}_{\theta}(\hat{\sigma}^2) + b(\sigma^2, \hat{\sigma}^2) = \frac{(2n-1)\sigma^4}{n^2}$$

设 $S(x)$ 和 $T(x)$ 是参数 $q(\theta)$ 的两个估计, 如果对  
所有 $\theta \in \Theta$ 不等式

$$R(\theta, T) \leq R(\theta, S)$$

成立, 且对某些 $\theta$ 严格不等式成立, 则称 $T$ 比 $S$ 好,  
也说 $S$ 是非容许的(Inadmissible)。

**例1.4.2:** 设 $x_1, x_2, \dots, x_n$ 是来自正态总体 $N(\mu, \sigma^2)$ 的简单样本,  $\mu$ 和 $\sigma^2$ 未知。在均方误差准则下, 试判断总体方差 $\sigma^2$ 的两个估计样本方差 $S^2$ 和样本二阶中心矩 $\hat{\sigma}^2$ 的优劣。

解 令 $\Theta = \{(\mu, \sigma^2): \mu \in R, \sigma^2 > 0\}$ 。由于

$$\frac{(n-1)S^2}{\sigma^2} \sim \chi^2(n-1)$$

所以

$$E_{\theta} \left[ \frac{(n-1)S^2}{\sigma^2} \right] = n-1, \text{Var}_{\theta} \left[ \frac{(n-1)S^2}{\sigma^2} \right] = 2(n-1)$$



从而

$$MSE_{\theta}(S^2) = Var_{\theta}(S^2) + b^2(\sigma^2, S^2) = \frac{2\sigma^4}{n-1}$$

再由例1.4.1可知,  $MSE_{\theta}(\hat{\sigma}^2) = \frac{(2n-1)\sigma^4}{n^2}$ 。所以, 当  $n > 1$  时, 对所有  $\theta \in \Theta$  都有

$$MSE_{\theta}(\hat{\sigma}^2) < MSE_{\theta}(S^2)$$

因此, 在均方误差标准下要比优。



从均方误差可知，我们自然希望估计的MSE越小越好。

用 $G_q$ 表示 $q(\theta)$ 所有可能估计组成的类，如果在 $G_q$ 中存在一个元 $T^*$ 使得对任一 $T \in G_q$ ，有

$$R(\theta, T^*) \leq R(\theta, T)$$

对所有的 $\theta \in \Theta$ 成立，则 $T^*(x)$ 应是 $q(\theta)$ 的最好估计。



遗憾的是，这样的估计 $T^*$ 并不存在，因为倘若这样的估计 $T^*(x)$ 存在，那么对任一 $\theta_0 \in \Theta$ ，令 $S(x) = q(\theta_0)$ ，则 $R(\theta_0, S) = 0$ ，这样

$$R(\theta_0, T^*) = E_{\theta_0} (T^*(x) - q(\theta_0))^2 \leq R(\theta_0, S) = 0$$

即 $T^*(x) = q(\theta_0)$ 。由 $\theta_0$ 的任意性，因此这样 $T^*(x)$ 不存在



平凡估计  
(*Trivial Estimate*)

由此可见，均方误差一致达到最小的最优估计并不存在，那么应如何评判和寻找优良的估计呢？方法之一是对估计提出一些合理性的要求，讲那些诸如不合理的平凡估计排除在外，然后在满足合理性要求的估计类中寻找优良的估计。无偏性便是一种常用的合理性要求。



定义1.4.1 设统计模型为 $\{P_\theta, \theta \in \Theta\}$ ,  $q(\theta)$ 未知参数,  $X_1, X_2, \dots, X_n$ 是来自总体样本,  $T$ 是一个统计量, 如果对所有的 $\theta \in \Theta$ 有

$$E(T(X)) = q(\theta)$$

成立, 即 $b(\theta, T) = 0$ , 则称 $T(X)$ 是参数 $q(\theta)$ 的无偏估计量 (*Unbiased Estimate*) 。



**例1.4.3:** 设 $x_1, x_2, \dots, x_n$ 是来自正态总体 $N(\mu, \sigma^2)$ 的简单样本, 求 $\mu$ 和 $\sigma^2$ 的无偏估计。

解 由于

$$\bar{x} \sim N\left(\mu, \frac{\sigma^2}{n}\right), \frac{n\hat{\sigma}^2}{\sigma^2} \sim \chi^2(n-1)$$

所以 $E_{\theta}(\bar{x}) = \mu, E_{\theta}(\hat{\sigma}^2) = \frac{(n-1)\sigma^2}{n}$ 。由此可见, 样本均值 $\bar{x}$ 是总体均值 $\mu$ 的无偏估计, 样本二阶中心矩 $\hat{\sigma}^2$ 是总体方差 $\sigma^2$ 的有偏估计。



由于 $E_{\theta} \left( \frac{n\hat{\sigma}^2}{n-1} \right) = \sigma^2$ , 所以 $\sigma^2$ 的无偏估计为

$$\frac{n\hat{\sigma}^2}{n-1} = \frac{1}{n-1} \sum_{i=1}^n (x_i - \bar{x})^2 = S^2$$

即样本方差 $S^2$ 是总体方差 $\sigma^2$ 的无偏估计。



注意:

(1) 无偏估计可能不存在。

如果参数 $q(\theta)$ 的无偏估计存在, 则称 $q(\theta)$ 是可估的。

若无特别声明, 均认为 $q(\theta)$ 是可估参数。

(2) 对可估参数 $q(\theta)$ , 无偏估计一般是不唯一的。

(3) 无偏估计不一定是最好的估计, 即它可能是非容许的。



(4) 在函数变换下, 无偏性可能消失, 即对 $\theta$ 而言,  
 $\hat{\theta}$ 是无偏的, 但 $q(\hat{\theta})$ 可能是 $q(\theta)$ 的有偏估计。

设 $q(\theta)$ 是可估参数, 令

$$U_q = \{T(x): E_{\theta}(T(x)) = q(\theta), \text{Var}_{\theta}(T(x)) < \infty, \theta \in \Theta\}$$

即 $U_q$ 表示参数 $q(\theta)$ 的所有无偏估计组成的类。

## § 1.5 一致最小方差无偏估计

设统计模型为 $\{P_\theta, \theta \in \Theta\}$ ,  $q(\theta)$ 是可估参数,  
 $U_q$ 是 $q(\theta)$ 的无偏估计类,  $q(\theta)$ 的一致最小方差无偏估计定义如下。

定义1.5.1 如果存在无偏估计 $T(x) \in U_q$ , 使得对任一的 $S(x) \in U_q$ , 有

$$\text{Var}_\theta(T(x)) \leq \text{Var}_\theta(S(x))$$

对所有的 $\theta \in \Theta$ 都成立



则称 $T(x)$ 为 $q(\theta)$ 的一致最小方差无偏估计，简称为UMVUE。

*(Uniformly Minimum Variance Unbiased Estimate)*

定理1.5.1（存在性） 设参数 $q(\theta)$ 是可估的，则

$T(x) \in U_q$ 是 $q(\theta)$ 一致最小方差无偏估计的充分必要条件是对任意的 $T_0(x) \in U_0$ ，等式

$$E_0(T_0(x)T(x)) = 0$$

对所有的 $\theta \in \Theta$ 都成立





推论 设 $T_1(x)$ 和 $T_2(x)$ 分别是可估函数 $q_1(\theta)$ 和 $q_2(\theta)$ 的一致最小方差无偏估计, 则对任一常数 $a$ 和 $b$ ,  $aT_1(x) + bT_2(x)$ 是 $aq_1(\theta) + bq_2(\theta)$ 的一致最小方差无偏估计。

定理1.5.2 (唯一性) 设参数 $q(\theta)$ 是可估的, 且 $T(x)$ 和 $S(x)$ 都是 $q(\theta)$ 的一致最小方差无偏估计, 则对所有的 $\theta \in \Theta$ , 有  $P_\theta\{T(x) = S(x)\} = 1$   
即在概率1下一致最小方差无偏估计是唯一的。







定理1.5.3 设统计模型为 $\{P_\theta, \theta \in \Theta\}$ ， $S(x)$ 是其充分统计量， $\varphi(x)$ 是 $q(\theta)$ 的无偏估计量，令

$$T(x) = E(\varphi(x)|S(x))$$

则 $T(x)$ 也是 $q(\theta)$ 的无偏估计量，且对所有的 $\theta \in \Theta$ ，有

$$\text{Var}_\theta(T(x)) \leq \text{Var}_\theta(\varphi(x))$$





证明：由条件期望的性质，得

$$E(T(x)) = E\left(E(\varphi(x)|S(x))\right) = E(\varphi(x)) = q(\theta)$$

所以 $T(x)$ 也是 $q(x)$ 的无偏估计。

$$\begin{aligned} \text{Var}_{\theta}(\varphi(x)) &= E_{\theta}(\varphi(x) - q(\theta))^2 \\ &= E_{\theta}(\varphi(x) - T(x) + T(x) - q(\theta))^2 \\ &= E_{\theta}(\varphi(x) - T(x))^2 + E_{\theta}(T(x) - q(\theta))^2 \\ &\quad + 2E_{\theta}\left((\varphi(x) - T(x))(T(x) - q(\theta))\right) \end{aligned}$$



$$\begin{aligned} & \text{但 } E_{\theta} \left( (\varphi(x) - T(x))(T(x) - q(\theta)) \right) \\ &= E_{\theta} \{ E_{\theta} [(\varphi(x) - T(x))(T(x) - q(\theta)) | S(x)] \} \\ &= E_{\theta} \{ (T(x) - q(\theta)) E_{\theta} [(\varphi(x) - T(x)) | S(x)] \} \end{aligned}$$

这是因为

$$\begin{aligned} & E_{\theta} [(\varphi(x) - T(x)) | S(x)] \\ &= E_{\theta} [\varphi(x) | S(x)] - E_{\theta} [T(x) | S(x)] = T(x) - T(x) \\ &= 0 \end{aligned}$$



$$\text{这样 } \text{Var}_{\theta}(\varphi(x)) = E_{\theta}(\varphi(x) - q(\theta))^2 = E_{\theta}(\varphi(x) - T(x))^2 + E_{\theta}(T(x) - q(\theta))^2 \geq E_{\theta}(T(x) - q(\theta))^2 = \text{Var}_{\theta}(T(x))$$

---

由此定理可知，利用充分统计量可以降低无偏估计量的方差，因此，为了寻找UMVUE，可以通过取充分统计量的条件期望（它是充分统计量的函数且是无偏的）来缩小无偏估计类。





若令  $U_q^T = \{E(\varphi(x)|T(x)): \text{all } \varphi(x) \in U_q\} \subset U_q$ , 则 UMVUE 若存在应属于  $U_q^T$ 。而  $U_q^T$  实际上是由  $U_q$  中充分统计量的所有函数组成的类, 这是因为若  $h(T(x)) \in U_q$ , 则由

$$E(h(T(x))|T(x)) = h(T(x))$$

可知  $h(T(x)) \in U_q^T$ 。这样可以在充分统计量的函数类  $U_q^T$  中寻找 UMVUE。但可能不唯一。为了在概率意义下确定唯一性, 还需对统计量提出合理要求, 这便是统计量的完全性。



定义1.5.2 设 $g(t)$ 是定义在统计量 $T(x)$ 的值域上的一实值函数，如果对所有的 $\theta \in \Theta$ ， $E_{\theta}(g(T)) = 0$ 成立时，必成立 $g(T) \equiv 0$ ，则称统计量 $T(x)$ 是完全的 (*Complete*)。

**例1.5.1** 设 $x_1, x_2, \dots, x_n$ 是来自两点分布 $b(1, \theta)$ 的样本 ( $0 < \theta < 1$ )，证明 $\bar{x}$ 是完全统计量。

证明 因为 $\bar{x}$ 服从类似 $b(n, \theta)$ 分布，所以

$$\begin{aligned} E_{\theta}(g(\bar{x})) &= \sum_{k=0}^n g\left(\frac{k}{n}\right) \binom{n}{k} \theta^k (1 - \theta)^{n-k} \\ &= (1 - \theta)^n \sum_{k=0}^n g\left(\frac{k}{n}\right) \binom{n}{k} \left(\frac{\theta}{1 - \theta}\right)^k \end{aligned}$$

令 $E_{\theta}(g(\bar{x})) = 0$ ，有

$$\sum_{k=0}^n g\left(\frac{k}{n}\right) \binom{n}{k} \left(\frac{\theta}{1-\theta}\right)^k = 0$$

因为上式的左边是 $\frac{\theta}{1-\theta}$ 的多项式，因此对所有的

$$\theta (\theta \in (0, 1))$$

$$\text{即 } g\left(\frac{k}{n}\right) = 0, k = 0, 1, \dots, n$$

故对分布族 $b(1, \theta)$ 而言， $\bar{x}$ 是完全统计量。



定理1.5.4 设 $x = (x_1, x_2, \dots, x_n)$ 是来自总体 $\{P_\theta, \theta \in \Theta\}$ 的一个样本，其密度函数可表示为

$$p(x, \theta) = c(w)h(x)\exp\left\{\sum_{k=1}^m w_k T_k(x)\right\}$$

其中 $w = w(\theta) = (w_1(\theta), \dots, w_m(\theta)) \in \Omega \subset R^m$ 。

$$(T_1(x), \dots, T_m(x)) = (\sum_{i=1}^n T_1(x_i), \dots, \sum_{i=1}^n T_m(x_i)),$$

如果 $\Omega$ 有内点，则统计量 $(T_1(x), \dots, T_m(x))$ 是完全充分的。

**例1.5.2:** 设 $x_1, x_2, \dots, x_n$ 是来自两点分布 $B(1, \theta)$ 总体的简单样本, 其中 $0 < \theta < 1$ , 求 $\theta$ 的完全充分统计量。

解 两点分布 $B(1, \theta)$ 分布列为 $p(x; \theta) = \theta^x(1 - \theta)^{1-x}$ , 其中 $x = 0, 1$ 。样本的联合分布列可分解为

$$\begin{aligned} p(x_1, x_2, \dots, x_n; \theta) &= \prod_{i=1}^n \theta^{x_i} (1 - \theta)^{1-x_i} \\ &= (1 - \theta)^n \exp \left\{ \left( \ln \frac{\theta}{1 - \theta} \right) \sum_{i=1}^n x_i \right\} \end{aligned}$$

$$\text{取 } w(\theta) = \ln \frac{\theta}{1-\theta}, c(\theta) = (1-\theta)^n,$$

$$h(x_1, x_2, \cdots, x_n) \equiv 1, \quad T(x_1, x_2, \cdots, x_n) = \sum_{i=1}^n x_i.$$

由于  $w(\theta)$  的值域  $\Lambda = (-\infty, +\infty)$  中包含内点, 所以由定理1.5.4可知  $T(x_1, x_2, \cdots, x_n) = \sum_{i=1}^n x_i$  是完全统计量。



**例1.5.3** 设总体 $X$ 服从对数正态分布 $LN(\mu, \sigma^2)$ ,

$x_1, x_2, \dots, x_n$ 是简单样本, 求完全统计量。

解 对数分布密度函数为

$$\begin{aligned} p(x; \theta) &= \frac{1}{\sqrt{2\pi}\sigma x} \exp\left\{-\frac{(\ln x - \mu)^2}{2\sigma^2}\right\} \\ &= \frac{1}{\sqrt{2\pi}\sigma} e^{-\frac{\mu^2}{2\sigma^2}} \exp\left\{\frac{\mu^2}{\sigma^2} \ln x - \frac{1}{2\sigma^2} (\ln x)^2\right\} \cdot \frac{1}{x} \end{aligned}$$

其中 $\theta = (\mu, \sigma^2) \in \Theta = (0, +\infty) \times (0, +\infty), x > 0$





因此样本的联合密度为

$$p(x_1, x_2, \dots, x_n; \theta) \\ = \left( \frac{1}{\sqrt{2\pi}\sigma} \right)^n e^{-\frac{n\mu^2}{2\sigma^2}} \cdot \frac{1}{\prod_{i=1}^n x_i} \cdot \exp \left\{ \frac{\mu^2}{\sigma^2} \sum_{i=1}^n \ln x_i - \frac{1}{2\sigma^2} \sum_{i=1}^n (\ln x_i)^2 \right\}$$

$$\text{这样 } (T_1(x), T_2(x)) = \left( \sum_{i=1}^n \ln x_i, \sum_{i=1}^n (\ln x_i)^2 \right)$$

$$w = w(\theta) = \left( \frac{\mu}{\sigma^2}, -\frac{1}{2\sigma^2} \right) \in \Omega = (0, +\infty) \times (-\infty, 0)$$

$$w: (0, +\infty) \times (0, +\infty) = \Theta \rightarrow \Omega$$

$$= (0, +\infty) \times (-\infty, 0)$$





由于二维区域 $\Omega$ 有内点, 所以 $(T_1(x), T_2(x)) = (\sum_{i=1}^n \ln x_i, \sum_{i=1}^n (\ln x_i)^2)$ 是完全充分统计量。

---

有关应用定理1.5.4的说明:

从这个例子可以看出, 实际上只需把总体的密度函数分解成 $p(x, \theta) = c(w)h(x)\exp\{\sum_{k=1}^m w_k T_k(x)\}$ ,  $T_k(x) = \sum_{i=1}^n T_k(x_i)$ 的形式可直接由指数函数的性质和样本的独立性获得。



### 定理1.5.5 (Lehmann-Scheffe)

设 $S(x)$ 是完全充分统计量,  $\varphi(x)$ 是 $q(\theta)$ 无偏估计, 则 $T(x) = E_{\theta}(\varphi(x)|S(x))$ 是 $q(\theta)$ 的UMVUE, 进一步如果对所有 $\theta \in \Theta$ ,  $Var_{\theta}(T(x)) < \infty$ , 则 $T(x)$ 是 $q(\theta)$ 唯一的UMVUE。



证明 由定理1.5.3可知 $T(x)$ 是 $q(\theta)$ 的无偏估计, 且对一切 $\theta \in \Omega$ , 有

$$\text{Var}_{\theta}(T(x)) \leq \text{Var}_{\theta}(\varphi(x))$$

即 $T(x) \in U_q^S$ , 因此只要能证明 $U_q^S$ 中元在概率1下都是相同的即可。

设 $T_1 = h_1(S)$ 和 $T_2 = h_2(S)$ 是中任意两个元, 则对一切 $\theta \in \Omega$ , 有

$$E_{\theta}(h_1(S) - h_2(S)) = E_{\theta}(h_1(S)) - E_{\theta}(h_2(S)) = 0$$





由于 $S$ 是完全统计量, 根据定义一切 $\theta \in \Omega$ , 有  
 $P_{\theta}\{h_1(S) = h_2(S)\} = 1$ , 这实际上说明 $T(x) =$   
 $E_{\theta}(\varphi(x)|S(x))$ 不依赖于无偏估计 $\varphi(x) \in U_q$ 。所以  
在概率1下,  $T(x)$ 是 $q(\theta)$ 唯一的一致最小方差无偏  
估计。



注：Lehmann-Scheffe定理实际上给出了两种寻找UMVUE的方法，但必须知道完全充分统计量 $T(x)$

(1) 若 $h(T(x))$ 是 $q(\theta)$ 无偏统计量，则 $h(T(x))$ 也是 $q(\theta)$ 的UMVUE。即寻找完全充分统计量的函数使之成为 $q(\theta)$ 的无偏估计。

(2) 若能获得 $q(\theta)$ 的一个无偏估计量 $\varphi(x)$ ，则 $E(\varphi(x)|S(x))$ 就是 $q(\theta)$ 的UMVUE。



**例1.5.4:** 设 $x_1, x_2, \dots, x_n$ 是来自Poisson总体 $P(\lambda)$ 的简单样本,  $\lambda$ 是正的未知参数。试求 $q(\lambda) = e^{-\lambda}$ 的一致最小方差无偏估计。

解 由于总体 $X$ 的分布列可分解为

$$p(x; \lambda) = \frac{\lambda^x}{x!} e^{-\lambda} = \frac{1}{x!} \exp\{(\ln \lambda)x\}, x = 0, 1, 2, \dots$$

从而样本 $x_1, x_2, \dots, x_n$ 的联合分布列有分解式

$$p(x_1, x_2, \dots, x_n; \lambda) = e^{-n\lambda} \prod_{i=1}^n \frac{1}{x_i!} \exp\left\{(\ln \lambda) \sum_{i=1}^n x_i\right\}$$



取  $S(x_1, x_2, \dots, x_n) = \sum_{i=1}^n x_i$ ,  $w(\lambda) = \ln \lambda$ ,  $c(\lambda) = e^{-n\lambda}$ ,  $h(x_1, x_2, \dots, x_n) = \prod_{i=1}^n \frac{1}{x_i!}$ 。由于  $w(\lambda) = \ln \lambda$  的值域为  $\Lambda = (-\infty, +\infty)$ , 且  $\Lambda$  中有内点, 则由定理1.5.4可知, 统计量  $S(x_1, x_2, \dots, x_n) = \sum_{k=1}^n x_k$  是完全充分的。



要直接寻找完全充分统计量 $S(x_1, x_2, \dots, x_n)$ 的某个函数 $h(S(x_1, x_2, \dots, x_n))$ ，使之成为 $q(\lambda) = e^{-\lambda}$ 的无偏估计是困难的，相对来说容易获得 $q(\lambda)$ 的一个无偏估计。

为此，令 $\varphi(x_1, x_2, \dots, x_n) = I_{\{x_1=0\}}(x_1, x_2, \dots, x_n)$ ，则

$$E_{\lambda}(\varphi(x_1, x_2, \dots, x_n)) = P_{\lambda}\{x_1 = 0\} = e^{-\lambda} = q(\lambda)$$

因此 $\varphi(x_1, x_2, \dots, x_n)$ 是 $q(\lambda)$ 的无偏估计。由定理1.5.5知

$T(x_1, x_2, \dots, x_n) = E_{\lambda}(\varphi(x_1, x_2, \dots, x_n) | S(x_1, x_2, \dots, x_n))$   
就是 $q(\lambda)$ 的一致最小方差无偏估计。

下面求条件期望，由于

$$E_{\lambda}(\varphi(x_1, x_2, \dots, x_n) | S(x_1, x_2, \dots, x_n) = s)$$

$$= P\left\{x_1 = 0 \mid \sum_{i=1}^n x_i = s\right\} = \frac{P\{x_1 = 0\}P\{\sum_{k=2}^n x_k = s\}}{P\{\sum_{k=1}^n x_k = s\}}$$

由独立Poisson随机变量之和仍服从Poisson分布，有

$$\sum_{k=2}^n x_k \sim P((n-1)\lambda), \quad \sum_{k=1}^n x_k \sim P(n\lambda)$$

代入可得

$$E_{\lambda} \left( \varphi(x_1, x_2, \dots, x_n) \mid \sum_{i=1}^n x_i = s \right) = \left( \frac{n-1}{n} \right)^s$$

因此有

$$E_{\lambda} \left( \varphi(x_1, x_2, \dots, x_n) \mid \sum_{i=1}^n x_i \right) = \left( \frac{n-1}{n} \right)^{\sum_{i=1}^n x_i}$$

因而统计量  $T(x_1, x_2, \dots, x_n) = \left( \frac{n-1}{n} \right)^{n\bar{x}}$  是  $q(\lambda) = e^{-\lambda}$  的一致最小方差无偏估计

**例1.5.5** 设总体 $X$ 服从正态分布 $N(\mu, \sigma^2)$ ,  $\theta = (\mu, \sigma^2)$ 未知,  $x_1, x_2, \dots, x_n$ 是来自总体的样本, 求参数 $\mu$ 和 $\sigma^2$ 的UMVUE。

解 首先求完全充分统计量。由于

$$\begin{aligned} p(x; \theta) &= \frac{1}{\sqrt{2\pi}\sigma} \exp \left\{ -\frac{(x - \mu)^2}{2\sigma^2} \right\} \\ &= \frac{1}{\sqrt{2\pi}\sigma} e^{-\frac{\mu^2}{2\sigma^2}} \exp \left\{ \frac{\mu^2}{\sigma^2} x - \frac{1}{2\sigma^2} x^2 \right\} \end{aligned}$$





由于  $w = \left(\frac{\mu}{\sigma^2}, -\frac{1}{2\sigma^2}\right)$  的值域包含内点，所以由定理4.2可知完全充分统计量为

$$T(x) = \left( \sum_{i=1}^n x_i, \sum_{i=1}^n x_i^2 \right)$$

而我们已经知道  $\bar{x} = \frac{1}{n} \sum_{i=1}^n x_i$  是  $\mu$  的无偏估计，且是完全充分统计量  $T(x)$  的函数，故当  $\sigma^2$  未知时， $\mu$  的UMVUE为  $\bar{x}$ 。

（注：无论  $\sigma^2$  是已知或未知， $\bar{x}$  都是  $\mu$  的UMVUE）



又  $S^2 = \frac{1}{n-1} \sum_{i=1}^n (x_i - \bar{x})^2$  是  $\sigma^2$  的无偏估计，且是完全充分统计量  $T(x)$  的函数，故当  $\mu$  未知时， $\sigma^2$  的UMVUE为样本方差  $S^2$ 。

（注，当  $\mu$  已知时， $S^2$  不是  $\sigma^2$  的UMVUE）

**例1.5.6** 设总体 $X$ 在 $[0, \theta]$ 上服从均匀分布，其中 $\theta$ 是未知参数， $x_1, x_2, \dots, x_n$ 是来自总体的样本，试求参数 $\theta$ 的UMVUE。

解 由于

$$p(x_1, x_2, \dots, x_n; \theta) = \begin{cases} \frac{1}{\theta^n}, & 0 \leq x_{(1)} \leq x_{(n)} \leq \theta \\ 0, & \text{otherwise} \end{cases}$$

由因子分解定理可知 $x_{(n)} = \max\{x_1, x_2, \dots, x_n\}$ 是充分统计量。下证它也是完全的。

由  $P\{x_{(n)} \leq t\} = (P\{x_1 \leq t\})^n$  可知  $x_{(n)}$  的密度函数为

$$p(t; \theta) = \begin{cases} n\theta^{-n}t^{n-1}, & 0 \leq t \leq \theta \\ 0, & \text{otherwise} \end{cases}$$

对任何函数  $g(t)$  及  $\theta > 0$ , 由

$$E_{\theta}(g(x_{(n)})) = n\theta^{-n} \int_0^{\theta} g(t)t^{n-1}dt = 0$$



可得对所有的  $\theta > 0$ ，有  $\int_0^\theta g(t)t^{n-1}dt = 0$ ，这个只有在  $g(t) \equiv 0$  时才能成立，因而  $x_{(n)}$  也是完全的。

又因为

$$E_\theta(x_{(n)}) = \frac{n}{\theta^n} \int_0^\theta t^n dt = \frac{n\theta}{n+1}$$

所以  $\theta$  的无偏估计为

$$\hat{\theta} = \frac{n+1}{n} x_{(n)}$$

是完全充分统计量  $x_{(n)}$  的函数，故它就是  $\theta$  的UMVUE。



## § 1.6 信息不等式

在上一节，我们知道如果UMVUE存在，则它在无偏估计类中是最好的，且其方差不可能是零，因为参数 $q(\theta)$ 的方差为零的平凡估计不是无偏估计。那么，现在的问题是：

对 $q(\theta)$ 的无偏估计类 $U_q$ ，在一定条件下

(1) 既然无偏估计的方差不是零，则必然存在一个下界，这个下界到底是多少？

(2) 若UMVUE存在, 那么它的方差是否可以达到这个下界?

问题(1)已由Cramer-Rao不等式(信息不等式)揭示; 问题(2)不一定成立, 我们举例予以阐述。

设分布族为 $\{P_\theta, \theta \in \Theta\}$ , 密度函数为 $p(x, \theta)$ ,  $\Theta$ 为直线上的一个开区间。满足下述条件的分布族 $\{P_\theta, \theta \in \Theta\}$ 称为Cramer-Rao族。



(1) 支撑  $A = \{x: p(x, \theta) > 0\}$  与  $\theta$  无关, 且对任一  $x \in A$ , 偏导数  $\frac{\partial}{\partial \theta} \ln p(x, \theta)$  存在。

(2) 若对所有  $\theta \in \Theta$ ,  $T(x)$  是满足  $E_{\theta}|T| < \infty$  任一统计量, 则对  $T(x)p(x, \theta)$ , 积分和微分可交换次序, 即

$$\begin{aligned} & \frac{\partial}{\partial \theta} \int_{-\infty}^{+\infty} \dots \int_{-\infty}^{+\infty} T(x) p(x, \theta) dx_1 \dots dx_n \\ &= \int_{-\infty}^{+\infty} \dots \int_{-\infty}^{+\infty} T(x) \frac{\partial}{\partial \theta} p(x, \theta) dx_1 \dots dx_n \end{aligned}$$





当仅有 (1) 成立时, 我们可以定义所谓的Fisher信息量 (Fisher Information Number)

$$I(\theta) = E \left[ \frac{\partial}{\partial \theta} \ln p(x, \theta) \right]^2 \quad (0 \leq I(\theta) \leq \infty)$$

如果

$$\frac{d^2}{d\theta^2} \int_{-\infty}^{+\infty} p(x; \theta) dx = \int_{-\infty}^{+\infty} \frac{\partial^2 p(x; \theta)}{\partial \theta^2} dx$$

成立, 可以证明  $I(\theta) = -E_{\theta} \left[ \frac{\partial^2}{\partial \theta^2} \ln p(x; \theta) \right]$

例1.6.1 设总体分布是Poisson分布族，即

$$p(x, \theta) = \frac{\theta^x}{x!} e^{-\theta}, x = 0, 1, \dots$$

则 
$$\frac{\partial}{\partial \theta} \ln p(x, \theta) = \frac{x}{\theta} - 1$$

$$\text{因而 } I(\theta) = E\left(\frac{x}{\theta} - 1\right)^2 = \text{Var}\left(\frac{x}{\theta}\right) = \frac{1}{\theta}$$

---

如果 $X_1, X_2, \dots, X_n$ 是来自总体的样本，可以证明

$$I(\theta) = nI_1(\theta), \text{ 其中 } I_1(\theta) = E\left(\frac{\partial}{\partial \theta} \ln p(X_1, \theta)\right)^2$$

统计量 $T(x_1, x_2, \dots, x_n)$ 是对样本 $x_1, x_2, \dots, x_n$ 进行加工或压缩，提取参数 $\theta$ 的信息过程，在这个过程中有可能损失的信息。若将统计量 $T(x_1, x_2, \dots, x_n)$ 的密度函数或分布列记为 $p_T(t; \theta)$ ，则它所包含的信息量为

$$I_T(\theta) = E_{\theta} \left[ \frac{\partial}{\partial \theta} \ln p_T(t; \theta) \right]^2$$

因此，直观上应该有 $I_T(\theta) \leq I_n(\theta)$ 。

理论上，在一定的条件下可以证明这个不等式确实成立，而且等号当且仅当 $T(x_1, x_2, \dots, x_n)$ 是充分统计量时成立，说明加工处理中信息没有损失，这更进一步加深了对充分统计量的理解，也说明将 $I(\theta)$ 作为信息多少的度量是合理的。

### 定理1.6.1 (Information Inequality)

设 $T(x)$ 是对 $\theta \in \Theta$ 所有满足 $Var_{\theta}(T(X)) < +\infty$ 的统计量, 记 $\varphi(\theta) = E_{\theta}(T(X))$ 。如果分布族是Cramer-Rao正则族, 且 $0 < I(\theta) < +\infty$ , 则对所有的 $\theta \in \Theta$ ,  $\varphi(\theta)$ 是可微的, 且

$$Var_{\theta}(T(X)) \geq \frac{(\varphi'(\theta))^2}{I(\theta)}$$

证明 由于对所有  $\theta \in \Theta$ , 有

$$\varphi(\theta) = \int_{-\infty}^{+\infty} \dots \int_{-\infty}^{+\infty} T(x) p(x, \theta) dx_1 \dots dx_n$$

等式两边求导可得

$$\begin{aligned} \varphi'(\theta) &= \int_{-\infty}^{+\infty} \dots \int_{-\infty}^{+\infty} T(x) \frac{\partial}{\partial \theta} p(x, \theta) dx_1 \dots dx_n \\ &= \int_{-\infty}^{+\infty} \dots \int_{-\infty}^{+\infty} T(x) \frac{\partial}{\partial \theta} (\ln p(x, \theta)) p(x, \theta) dx_1 \dots dx_n \\ &= E \left( T(x) \frac{\partial}{\partial \theta} \ln p(x, \theta) \right) \end{aligned}$$

又因为对所有的 $\theta \in \Theta$ , 有

$$\int_{-\infty}^{+\infty} \dots \int_{-\infty}^{+\infty} p(x, \theta) dx_1 \dots dx_n = 1$$

等式两边求导可得

$$\int_{-\infty}^{+\infty} \dots \int_{-\infty}^{+\infty} \frac{\partial}{\partial \theta} p(x, \theta) dx_1 \dots dx_n = 0$$

$$\int_{-\infty}^{+\infty} \dots \int_{-\infty}^{+\infty} \frac{\partial \ln p(x, \theta)}{\partial \theta} p(x, \theta) dx_1 \dots dx_n = 0$$

这样就有

$$E \left( \frac{\partial \ln p(x, \theta)}{\partial \theta} \right) = 0$$



从而有

$$\begin{aligned}\varphi'(\theta) &= E\left(T(x) \frac{\partial}{\partial \theta} \ln p(x, \theta)\right) \\ &= \text{Cov}\left(T(x), \frac{\partial}{\partial \theta} \ln p(x, \theta)\right)\end{aligned}$$

$$\begin{aligned}\text{有 } |\varphi'(\theta)| &= \left| \text{Cov}\left(T(x), \frac{\partial}{\partial \theta} \ln p(x, \theta)\right) \right| \\ &\leq \sqrt{\text{Var}(T(X))} \sqrt{\text{Var}\left(\frac{\partial}{\partial \theta} \ln p(x, \theta)\right)}\end{aligned}$$



而

$$\text{Var}\left(\frac{\partial \ln p(x, \theta)}{\partial \theta}\right) = E\left(\frac{\partial \ln p(x, \theta)}{\partial \theta}\right)^2 = I(\theta)$$

所以有

$$|\varphi'(\theta)| \leq \sqrt{\text{Var}(T(X))} \sqrt{I(\theta)}$$

即

$$\text{Var}_{\theta}(T(X)) \geq \frac{(\varphi'(\theta))^2}{I(\theta)}$$

在信息不等式中，下界通过 $\varphi(\theta)$ 依赖于 $q(\theta)$ ，因它是 $T(x)$ 的数学期望，也就是说对不同统计量而言，下界是变化的，如果将此定理应用于参数 $q(\theta)$ 的无偏估计类 $U_q$ ，就有：

对参数 $q(\theta)$ 的任意无偏估计 $T(x) \in U_q$ ，有

$$\text{Var}_{\theta}(T(X)) \geq \frac{(q'(\theta))^2}{I(\theta)}$$

特别地，当 $q(\theta) = \theta$ 时，对任一 $T(X) \in U_\theta$ ，有

$$\text{Var}_\theta(T(X)) \geq \frac{1}{I(\theta)}$$

通常称量 $\frac{1}{I(\theta)}$ 为Cramer-Rao下界。

注意：（1）在以上三个不等式中 $I(\theta) = nI_1(\theta)$

通常将 $I_1(\theta)$ 看成一次观察所能获得的关于参数 $\theta$ 的信息，即一个观测值 $X_1$ 所含 $\theta$ 的信息，那么 $I(\theta)$ 就表示样本 $X_1, X_2, \dots, X_n$ 所含的信息。

(2) 在将定理应用于无偏估计类 $U_q$ 时，一定要注意定理的条件是否满足。

例1.6.2 设 $x_1, x_2, \dots, x_n$ 是来自总体的简单样本，其密度函数为

$$p(x; \theta) = \begin{cases} e^{-(x-\theta)}, & x > \theta \\ 0, & x \leq \theta \end{cases}$$

其中参数 $\theta > 0$ 。证明 $\hat{\theta} = x_{(1)} - \frac{1}{n}$ 是 $\theta$ 的无偏估计，

且 $Var(\hat{\theta}) < \frac{1}{nI(\theta)}$ 。

证明 首先证明  $\hat{\theta} = x_{(1)} - \frac{1}{n}$  是  $\theta$  的无偏估计。由样本的独立性和同分布性，有  $x_{(1)}$  的分布函数为

$$\begin{aligned} F_{x_{(1)}}(y; \theta) &= P_{\theta}\{x_{(1)} \leq y\} = 1 - P_{\theta}\{x_{(1)} > y\} \\ &= 1 - [1 - F(y; \theta)]^n \end{aligned}$$

其中  $F(y; \theta)$  是总体  $X$  的分布函数。关于  $y$  求导，可得  $x_{(1)}$  的密度函数为

$$g(y; \theta) = \begin{cases} ne^{-n(y-\theta)}, & y > \theta \\ 0, & y \leq \theta \end{cases}$$

因此,  $x_{(1)}$ 的数学期望为

$$\begin{aligned} E_{\theta}(x_{(1)}) &= n \int_0^{+\infty} y e^{-n(y-\theta)} dy \\ &= \theta + \int_0^{+\infty} e^{-n(y-\theta)} dy = \theta + \frac{1}{n} \end{aligned}$$

移项可得 $E_{\theta}\left(x_{(1)} - \frac{1}{n}\right) = \theta$ , 从而 $\hat{\theta} = x_{(1)} - \frac{1}{n}$ 是 $\theta$ 的无偏估计。

下面计算 $\hat{\theta} = x_{(1)} - \frac{1}{n}$ 的方差。

$$\text{Var}(\hat{\theta}) = \text{Var}_{\theta}(x_{(1)}) = E_{\theta}(x_{(1)}^2) - [E(x_{(1)})]^2$$

$$= n \int_0^{+\infty} y^2 e^{-n(y-\theta)} dy - \left(\theta + \frac{1}{n}\right)^2$$

$$= \theta^2 + 2 \int_0^{+\infty} ye^{-n(y-\theta)} dy - \left(\theta + \frac{1}{n}\right)^2 = \frac{1}{n^2}$$



由于

$$I(\theta) = E_{\theta} \left[ \frac{\partial}{\partial \theta} \ln p(x; \theta) \right]^2 = \int_0^{+\infty} e^{-(y-\theta)} dy = 1$$

所以，C-R下界为  $\frac{1}{nI(\theta)} = \frac{1}{n}$ 。从而，当样本容量  $n > 1$  时，有

$$\text{Var}_{\theta} \left( x_{(1)} - \frac{1}{n} \right) < \frac{1}{nI(\theta)}$$

当一致最小方差无偏估计存在、不等式成立时一致最小方差无偏估计的方差未必能达到C-R下界，举例如下。

例1.6.3 设 $X_1, X_2, \dots, X_n$ 是来自正态总体 $N(\mu, 1)$ 的一个简单样本。试求参数 $\mu^2$ 的UMVUE, 并证明其方差大于信息不等式的下界。

---

解 由于

$$\begin{aligned} p(x, \mu) &= \frac{1}{\sqrt{2\pi}} \exp \left\{ -\frac{(x - \mu)^2}{2} \right\} \\ &= \frac{1}{\sqrt{2\pi}} \exp \left\{ -\frac{\mu^2}{2} \right\} \exp \left\{ -\frac{x^2}{2} \right\} \exp \{\mu x\} \end{aligned}$$

由定理1.5.3知完全充分统计量为 $\sum_{i=1}^n X_i$ ，所以 $\mu$ 的

UMVUE为 $\bar{X}$ ，且服从 $N(\mu, \frac{1}{n})$ ，而由

$$\frac{1}{n} = \text{Var}(\bar{X}) = E(\bar{X}^2) - (E(\bar{X}))^2 = E(\bar{X}^2) - \mu^2$$

有 $E(\bar{X}^2 - \frac{1}{n}) = \mu^2$ ，这样 $\bar{X}^2 - \frac{1}{n}$ 是 $\mu^2$ 无偏估计，

且是 $\bar{X}$ 的函数，所以它是 $\mu^2$ 的UMVUE。为计算

UMVUE方差，令 $Z = \sqrt{n}(\bar{X} - \mu)$

则 $Z$ 服从标准正态分布 $N(0, 1)$ 。则

$$\begin{aligned} \text{Var}\left(\bar{X}^2 - \frac{1}{n}\right) &= \text{Var}(\bar{X}^2) \\ &= \frac{1}{n^2} \text{Var}\left\{\left(Z + \sqrt{n}\mu\right)^2\right\} = \frac{2}{n^2} + \frac{4\mu^2}{n} \end{aligned}$$

而

$$\begin{aligned} I_1(\mu) &= E\left(\frac{\partial}{\partial\mu} \ln \frac{1}{\sqrt{2\pi}} \exp\left\{-\frac{(x-\mu)^2}{2}\right\}\right)^2 \\ &= E\left(\frac{\partial}{\partial\mu} \left\{-\frac{(x-\mu)^2}{2}\right\}\right)^2 = E(x-\mu)^2 = 1 \end{aligned}$$

所以

$$\text{Var}\left(\bar{X}^2 - \frac{1}{n}\right) = \frac{2}{n^2} + \frac{4\mu^2}{n} > \frac{4\mu^2}{n} = \frac{((\mu^2)')^2}{nI_1(\mu)}$$

这说明 $\mu^2$ 的UMVUE的方差未达到信息不等式的下界。

如果参数 $q(\theta)$ 的无偏估计的方差 $\hat{q}(X)$ 取得信息不等式的下界，即

$$\text{Var}(\hat{q}(X)) = \frac{(q'(\theta))^2}{I(\theta)}$$

则 $\hat{q}(X)$ 必是参数 $q(\theta)$ 的UMVUE。

例1.6.4 设 $X_1, X_2, \dots, X_n$ 来自正态总体 $N(0, \sigma^2)$ 的一个简单样本。试求参数 $\sigma^2$ 的UMVUE。

---

解 由于 $I_1(\sigma^2) = -E\left(\frac{\partial^2}{\partial(\sigma^2)^2} \ln p(X_1, \sigma^2)\right)$

$$= -E\left(\frac{\partial^2}{\partial(\sigma^2)^2} \ln \frac{1}{\sqrt{2\pi\sigma^2}} \exp\left\{-\frac{x^2}{2\sigma^2}\right\}\right)$$
$$= -E\left(\frac{1}{2(\sigma^2)^2} - \frac{x^2}{(\sigma^2)^3}\right) = \frac{1}{2(\sigma^2)^2}$$

从而  $I_1(\sigma^2) = \frac{n}{2(\sigma^2)^2}$ 。由信息不等式知，对任一无偏估计  $\hat{\sigma}^2(X) \in U_{\sigma^2}$ ，有

$$\text{Var}(\hat{\sigma}^2(X)) \geq \frac{\left((\sigma^2)'\right)^2}{I(\theta)} = \frac{2(\sigma^2)^2}{n}$$

若取  $\hat{\sigma}^2(X) = \frac{1}{n} \sum_{i=1}^n X_i^2$ ，由  $\frac{X_i^2}{\sigma^2}$  服从  $\chi^2(1)$  可知

$$\frac{n\hat{\sigma}^2(X)}{\sigma^2} = \sum_{i=1}^n \frac{X_i^2}{\sigma^2} \sim \chi^2(n)$$

所以

$$E\left(\frac{n\hat{\sigma}^2(X)}{\sigma^2}\right) = n, \text{Var}\left(\frac{n\hat{\sigma}^2(X)}{\sigma^2}\right) = 2n$$

即

$$E(\hat{\sigma}^2(X)) = \sigma^2, \text{Var}(\hat{\sigma}^2(X)) = \frac{2(\sigma^2)^2}{n}$$

故

$$\text{Var}(\hat{\sigma}^2(X)) = \frac{2(\sigma^2)^2}{n} = \frac{\left((\sigma^2)'\right)^2}{I(\theta)}$$

从而 $\hat{\sigma}^2(X) = \frac{1}{n} \sum_{i=1}^n X_i^2$ 是参数 $\sigma^2$ 的UMVUE。



定义1.6.1 设分布族 $\{P_\theta, \theta \in \Theta\}$ 是C-R正则族,  $q(\theta)$ 是可估参数, 如果存在某无偏估计 $\hat{q}(X) \in U_q$ , 其方差达到信息不等式的下界, 即

$$\text{Var}(\hat{q}(X)) = \frac{(q'(\theta))^2}{I(\theta)}$$

则称 $\hat{q}(X)$ 为 $q(\theta)$ 的有效估计(Efficient Estimate)。

定义1.6.2 对参数 $q(\theta)$ 的任一无偏估计 $\hat{q}(X) \in U_q$ ，令

$$e(\hat{q}(X)) = \frac{(q'(\theta))^2}{I(\theta)} / \text{Var}(\hat{q}(X))$$

则称 $e(\hat{q}(X))$ 为估计 $q(\theta)$ 的有效率（Efficiency）。

显然 $0 \leq e(\hat{q}(X)) \leq 1$ 。因此，有效估计是有效率为1的无偏估计。

理论上可以证明只有在指数分布族

$$\left\{ p(x; \theta) = c(\theta) \exp \left\{ \sum_{k=1}^m \omega_k(\theta) T_k(\theta) \right\} h(x), \theta \in \Theta \right\}$$

下，可估参数的有效估计才可能存在，且也并非任一可估参数都有有效估计，也就是说即使在指数分布族下，有效估计存在的情况少之又少。

**定义1.6.3** 设 $\{T_n(X)\}$ 是参数 $q(\theta)$ 的估计序列, 如果对所有 $\theta \in \Theta$ , 都有 $\lim_{n \rightarrow \infty} E_\theta(T_n(X)) = q(\theta)$ , 则称 $T_n(X)$ 为参数 $q(\theta)$ 的渐进无偏估计 (Asymptotic Unbiased Estimate)。

例如对正态总体 $N(\mu, \sigma^2)$ , 我们知道 $\hat{\sigma}_n^2$ 是总体方差 $\sigma^2$ 的有偏估计, 且

$$E(\hat{\sigma}_n^2) = \frac{n-1}{n} \sigma^2$$

这样有  $\lim_{n \rightarrow \infty} E(\hat{\sigma}_n^2) = \lim_{n \rightarrow \infty} \frac{n-1}{n} \sigma^2 = \sigma^2$

故  $\hat{\sigma}_n^2$  是总体方差  $\sigma^2$  的渐进无偏估计。

定义1.6.4 设  $q(\theta)$  是可估参数，如果存在无偏估计序列  $\hat{q}_n(X) \in U_q$ ，使得

$$\lim_{n \rightarrow \infty} e(\hat{q}(X)) = \lim_{n \rightarrow \infty} \frac{(q'(\theta))^2}{I(\theta)} / \text{Var}(\hat{q}(X)) = 1$$

成立，则称  $\hat{q}_n(X)$  为  $q(\theta)$  的渐进有效估计  
(Asymptotic Efficient Estimate)。

例如 $X_1, X_2, \dots, X_n$ 是来自正态总体 $N(0, \sigma^2)$ 的样本, 由

例1.6.4知方差 $\sigma^2$ 的有效估计是 $\frac{1}{n} \sum_{i=1}^n X_i^2$ 。

由于

$$\frac{(n-1)S_n^2}{\sigma^2} = \sum_{i=1}^n \frac{(X_i - \bar{X})^2}{\sigma^2} \sim \chi^2(n-1)$$

所以

$$E\left(\frac{(n-1)S_n^2}{\sigma^2}\right) = n-1, \text{Var}\left(\frac{(n-1)S_n^2}{\sigma^2}\right) = 2(n-1)$$

$$\text{即 } E(S_n^2) = \sigma^2, \text{Var}(S_n^2) = \frac{2(\sigma^2)^2}{n-1}$$

而Cramer-Rao下界为

$$\frac{1}{I(\sigma^2)} = \frac{2(\sigma^2)^2}{n}$$

这说明无偏估计 $S^2$ 既不是 $\sigma^2$ 的UMVUE，也不是有效估计。

但是

$$\lim_{n \rightarrow \infty} e(S_n^2) = \lim_{n \rightarrow \infty} \frac{\frac{1}{I(\sigma^2)}}{\text{Var}(S_n^2)}$$

故样本方差 $S_n^2$ 是 $\sigma^2$ 的渐进有效估计。需要说明的是当UMVUE的方差较大时，方差小的有偏估计也不失为一个好的估计。



## § 1.7 相合估计

当样本容量变大时，要求参数的估计量具有这种极限性质实际上是对估计量的基本要求，这就是下面要介绍估计量的相合性（Consistency）准则。

定义1.7.1 设 $\hat{q}_n(X) = \hat{q}_n(X_1, \dots, X_n)$ 是参数 $q(\theta)$ 的任一估计序列，如果 $\{\hat{q}_n\}$ 依概率收敛于参数真值 $q(\theta)$ ，即对任意的 $\varepsilon > 0$ ，有

$$\lim_{n \rightarrow \infty} P\{|\hat{q}_n(X) - q(\theta)| > \varepsilon\} = 0$$

则称 $\hat{q}_n(X)$ 是 $q(\theta)$ 的相合估计。(Consistent Estimate)  
相合性只是反映了 $n \rightarrow \infty$ 时估计量的性质，即大样本性质，当样本容量有限时是无意义的。一般情形下证明估计的相合性可使用定义或大数定律。

例1.7.1 设 $X_1, \dots, X_n$ 是来自 $[0, \theta]$ 上均匀分布总体的一个简单样本，试证明 $\theta$ 的MLE估计 $X_{(n)}$ 是其相合估计。

证明 可知 $X_{(n)}$ 的密度函数为

$$p(t; \theta) = \begin{cases} n\theta^{-n}t^{n-1}, & 0 \leq t \leq \theta \\ 0, & \text{otherwise} \end{cases}$$

$$\text{且 } E_{\theta}(X_{(n)}) = \frac{n\theta}{n+1}, \lim_{n \rightarrow \infty} E_{\theta}(X_{(n)}) = \lim_{n \rightarrow \infty} \frac{n\theta}{n+1} = \theta$$

所以 $X_{(n)}$ 是 $\theta$ 渐进无偏估计。

又因为对  $\forall \varepsilon > 0$ , 有

$$\begin{aligned} P\{|X_{(n)} - \theta| > \varepsilon\} &= P\{X_{(n)} \leq \theta - \varepsilon\} \\ &= n\theta^{-n} \int_0^{\theta-\varepsilon} t^{n-1} dt = \left(\frac{\theta - \varepsilon}{\theta}\right)^n \end{aligned}$$

$$\text{这样 } \lim_{n \rightarrow \infty} P\{|X_{(n)} - \theta| > \varepsilon\} = \lim_{n \rightarrow \infty} \left(\frac{\theta - \varepsilon}{\theta}\right)^n = 0$$

故  $X_{(n)}$  是  $\theta$  的相合估计。

---

下面的定理在证明估计的相合性时很有用。

定理1.7.1 如果 $\hat{q}_n(X)$ 是参数 $q(\theta)$ 相合估计, 且函数 $h(y)$ 在 $y = q(\theta)$ 处连续, 则 $h(\hat{q}_n)$ 是 $h(q(\theta))$ 的相合估计。



例1.7.2 在Hardy-Weinberg模型中同位基因之一发生频率 $\theta$ 的三个频率替换估计为

$$\hat{\theta}_1 = \sqrt{\frac{n_1}{n}}, \hat{\theta}_2 = 1 - \sqrt{\frac{n_3}{n}}, \hat{\theta}_3 = \frac{n_1}{n} + \frac{n_2}{2n}$$

又因为相应的函数

$$\theta = \sqrt{p_1}, \theta = 1 - \sqrt{p_3}, \theta = p_1 + \frac{p_2}{2}$$

都是连续函数，由大数定律知 $\frac{n_i}{n}$ 是 $p_i$ 的相合估计，

故由定理1.7.1知 $\hat{\theta}_1, \hat{\theta}_2, \hat{\theta}_3$ 都是 $\theta$ 的相合估计



注：

(1) 这里仅介绍（弱）相合性（依概率收敛），还有强相合性（依概率1收敛或几乎必然收敛）就不涉及。

(2) 相合性本身不能说明估计达到某一可靠度时，要求样本容量至少为多少。

(3) 对同一参数，满足相合性的估计也许有多个。

对于 (3)，当存在多个相合估计时，其优劣往往可通过比较其渐进分布的渐进方差的大小来进行，最常用的渐进分布为正态分布。

定义1.7.2 设  $\hat{q}_n(X) = \hat{q}_n(X_1, \dots, X_n)$  是  $q(\theta)$  估计序列，如果存在数列  $\mu_n(\theta)$  和  $\sigma_n^2(\theta)$ ，对任意实数  $x$ ，都有

$$\lim_{n \rightarrow \infty} P \left\{ \frac{\hat{q}_n(X) - \mu_n(\theta)}{\sigma_n(\theta)} \leq x \right\} = \frac{1}{\sqrt{2\pi}} \int_{-\infty}^x \exp \left\{ -\frac{u^2}{2} \right\} du$$

则称  $\hat{q}_n$  具有渐近正态性，简记为  $\frac{\hat{q}_n(X) - \mu_n(\theta)}{\sigma_n(\theta)} \xrightarrow{L} N(0, 1)$



渐进正态性并不能确定用

$$\Phi((x - \mu_n(\theta))/\sigma_n(\theta))$$

近似 $P\{\hat{q}_n(X) < x\}$ 达到某精度时的最小样本容量 $n$

一般情形下, 可取

$$\mu_n(\theta) = E(\hat{q}_n(X)), \sigma_n^2(\theta) = Var(\hat{q}_n(X))$$

(1) 对频率替换估计, 若 $h(p)$ 有连续偏导数, 则

$$\sqrt{n} \left( h\left(\frac{n_1}{n}, \dots, \frac{n_k}{n}\right) - h(p_1, \dots, p_k) \right) \xrightarrow{L} N(0, \sigma_h^2)$$

$$\text{其中 } \sigma_h^2 = \sum_{i=1}^k p_i \left( \frac{\partial h(p)}{\partial p_i} \right)^2 - \left( \sum_{i=1}^k p_i \frac{\partial h(p)}{\partial p_i} \right)^2$$

例1.7.3 在Hardy-Weinberg模型中,  $\theta$ 的三个频率替换估计

$$\hat{\theta}_1 = \sqrt{\frac{n_1}{n}}, \hat{\theta}_2 = 1 - \sqrt{\frac{n_3}{n}}, \hat{\theta}_3 = \frac{n_1}{n} + \frac{n_2}{2n}$$

都是相合估计, 究竟哪个最优呢? 比较其渐进正态分布的方差。它们相应的函数为

$$h_1 = \sqrt{p_1}, h_2 = 1 - \sqrt{p_3}, h_3 = p_1 + \frac{p_2}{2}$$

从而有  $\sqrt{n}(\hat{\theta}_i - h_i) \xrightarrow{L} N(0, \sigma_h^2)$

其中

$$\frac{\sigma_1^2}{n} = \frac{1}{4n} (1 - \theta^2), \frac{\sigma_2^2}{n} = \frac{1}{4n} (1 - (1 - \theta)^2)$$
$$\frac{\sigma_3^2}{n} = \frac{1}{2n} \theta (1 - \theta)$$

比较这三个渐进方差，可知 $\frac{\sigma_3^2}{n}$ 最小，因此可以认为

$\hat{\theta}_3 = \frac{n_1}{n} + \frac{n_2}{2n}$ 是 $\theta$ 的较好估计，实际上 $\hat{\theta}_3$ 是 $\theta$ 的MLE。

在一定条件下，可证明矩估计，MLE也有渐进正态性

(2) 设  $h(A_1, A_2, \dots, A_r)$  是参数  $q(\theta) = h(\mu_1(\theta), \mu_2(\theta), \dots, \mu_r(\theta))$  的矩估计, 若总体  $2r$  阶原点矩  $\mu_{2r} = E_\theta(X^{2r})$  有限, 且函数  $h(y_1, y_2, \dots, y_r)$  具有连续偏导数, 则

$$\sqrt{n}(h(A_1, A_2, \dots, A_r) - h(\mu_1, \mu_2, \dots, \mu_r)) \sim AN(0, \sigma_h^2)$$



其中

$$\begin{aligned}
 \sigma_h^2 &= \text{Var} \left[ \sum_{k=1}^r \frac{\partial}{\partial \mu_k} h(\mu_1, \mu_2, \dots, \mu_r) X^k \right] \\
 &= \sum_{i=1}^r \sum_{j=1}^r \frac{\partial}{\partial \mu_i} h(\mu_1, \mu_2, \dots, \mu_r) \frac{\partial}{\partial \mu_j} h(\mu_1, \mu_2, \dots, \mu_r) \text{Cov}(X^i, X^j) \\
 &= \sum_{k=2}^{2r} b_k \mu_k - \left[ \sum_{k=1}^r \mu_k \frac{\partial}{\partial \mu_k} h(\mu_1, \mu_2, \dots, \mu_r) \right]^2 \\
 b_k &= \sum_{\substack{i+j=k \\ 1 \leq i, j \leq r}} \frac{\partial}{\partial \mu_i} h(\mu_1, \mu_2, \dots, \mu_r) \frac{\partial}{\partial \mu_j} h(\mu_1, \mu_2, \dots, \mu_r), \\
 k &= 2, 3, \dots, 2r
 \end{aligned}$$

在很广的条件下，参数 $q(\theta)$ 的极大似然估计 $\hat{q}_n$ 是渐

进正态估计，其渐进方差 $\frac{\sigma^2(\theta)}{n} = \frac{[q'(\theta)]^2}{nI(\theta)}$ (C-R下界)，

或写成 $\hat{q}_n \sim AN\left(q(\theta), \frac{[q'(\theta)]^2}{nI(\theta)}\right)$ 的形式。